



ĐỒ ÁN MÔN HỌC

**THU THẬP VÀ PHÂN TÍCH DỮ LIỆU NHÀ ĐẤT
TỪ TRANG WEB BATDONGSAN.VN SỬ DỤNG
SELENIUM VÀ MONGODB**

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Môn học: **MÃ NGUỒN MỞ KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS.Lê Nhật Tùng

Sinh viên thực hiện :

2386400039 - Phạm Trường Phát

2386400022 - Đinh Quốc Khánh

2386400982 - Lê Đình Nhật Thắng



ĐỒ ÁN MÔN HỌC

**THU THẬP VÀ PHÂN TÍCH DỮ LIỆU NHÀ ĐẤT
TỪ TRANG BATDONGSAN.VN SỬ DỤNG
SELENIUM VÀ MONGODB**

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Môn học: **MÃ NGUỒN MỞ KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS.Lê Nhật Tùng

Sinh viên thực hiện :

2386400039 - Phạm Trường Phát

2386400022 - Đinh Quốc Khánh

2386400982 - Lê Đình Nhật Thắng

TP. Hồ Chí Minh, 2025

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

TPHCM, Ngày..... Tháng Năm 2025

Giáo viên hướng dẫn

(Ký tên, đóng dấu)

LỜI CAM ĐOAN

Nhóm chúng tôi gồm Phạm Trường Phát, Đinh Quốc Khanh, và Lê Đình Nhật
Thắng xin cam đoan rằng:

Tất cả thông tin và kết quả nghiên cứu trong bài báo cáo này đều trung thực và
khách quan, được thu thập từ các nguồn đáng tin cậy, chính thống. Chúng tôi đã phân
tích kỹ lưỡng các tài liệu và đảm bảo rằng mọi dữ liệu hoặc ý kiến trích dẫn đều được
ghi rõ ràng nguồn gốc, tuân thủ đúng quy định về trích dẫn học thuật.

Chúng tôi cam kết không có hành vi sao chép hoặc sử dụng trái phép bất kỳ
thông tin nào từ các nguồn khác. Bài báo cáo này là sản phẩm nghiên cứu độc lập của
nhóm, chưa từng được công bố trước đây và tuân thủ đầy đủ các quy định của môn
học. Chúng tôi sử dụng công cụ nghiên cứu một cách hợp lý và chính xác, đảm bảo
tính khoa học và đạo đức trong quá trình thực hiện.

Nhóm chúng tôi hy vọng rằng bài báo cáo sẽ cung cấp cái nhìn sâu sắc về chủ
đề “Thu thập, lưu trữ và phân tích dữ liệu bất động sản từ website batdongsan.com.vn”
và đóng góp tích cực vào phát triển của lĩnh vực này.

TPHCM, Ngày..... Tháng Năm 2025

Sinh viên

Phạm Trường Phát
Đinh Quốc Khanh
Lê Đình Nhật Thắng

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT VÀ TỪ KHOÁ

UC	Undetected Chromedriver để điều khiển trình duyệt Chrome tối ưu để tránh bị các website phát hiện là bot
HTML	HyperText Markup Language
XML	eXtensible Markup Language
BeautifulSoup	Thư viện Python dùng để phân tích HTML/XML
Selenium	Hệ thống tự động hoá trình duyệt
MongoDB	Hệ quản trị cơ sở dữ liệu NoSQL
CSS	Cascading Style Sheets, ngôn ngữ định dạng giao diện
lxml	Thư viện Python hỗ trợ phân tích cú pháp XML và HTML nhanh
MongoDB	Dịch vụ cơ sở dữ liệu đám mây
Atlas	
HTTP	HyperText Transfer Protocol, giao thức truyền tải siêu văn bản
DOM	Document Object Model là một cấu trúc dữ liệu dạng cây phân cấp, biểu diễn tất cả các phần tử
JSON	JavaScript Object Notation, định dạng trao đổi dữ liệu nhẹ
JS	JavaScript, Ngôn ngữ lập trình chạy trên trình duyệt, xử lý các tương tác động
unidecode	Thư viện Python dùng để chuyển đổi các ký tự Unicode phức tạp
AWS	Amazon Web Services, nền tảng điện toán đám mây

MỤC LỤC

DANH SÁCH BẢNG	8
DANH SÁCH HÌNH ẢNH, BIỂU ĐỒ	9
CHƯƠNG 1: TỔNG QUAN.....	11
1.1 Giới thiệu đề tài.....	11
1.2 Nhiệm vụ của đề tài.....	11
1.2.1 Tính cấp thiết của đề tài	11
1.2.2 Ý nghĩa khoa học và thực tiễn của đề tài	12
1.3 Mục tiêu.....	13
1.3.1 Mục tiêu tổng quát	13
1.3.2 Mục tiêu cụ thể	13
1.4 Đối tượng và phạm vi	13
1.4.1 Đối tượng.....	13
1.4.2 Phạm vi.....	13
1.5 Phương pháp nghiên cứu	13
1.5.1 Phương pháp nghiên cứu tài liệu	13
1.5.2 Phương pháp phân tích trang	14
1.5.3 Phương pháp thực nghiệm	14
1.5.4 Phương pháp kết hợp công cụ	14
1.5.5 Phương pháp đánh giá và phân tích dữ liệu	14
1.6 Những đóng góp nghiên cứu của đề tài.....	14
1.6.1 Trong lĩnh vực học thuật	14
1.6.2 Trong thực tiễn	14
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	15
2.1 Trích xuất dữ liệu web.....	15
2.1.1 Định nghĩa	15
2.1.2 Quy trình hoạt động	15
2.2 Selenium	16
2.2.1 Giới thiệu.....	16
2.2.2 Bộ công cụ selenium	16
2.3 Beautiful Soup.....	16
2.3.1 Giới thiệu.....	16

2.3.2 Kiến trúc và bộ phân tích cú pháp	16
2.3.3 Các đối tượng chính	17
2.3.4 Xử lý mã hóa	17
2.4 Cơ sở dữ liệu NoSQL	17
2.4.1 Giới thiệu.....	17
2.4.2 Ưu điểm của cơ sở dữ liệu NoSQL	18
2.4.3 Các trường hợp sử dụng cơ sở dữ liệu NoSQL	18
2.5 MongoDB	19
2.5.1 Giới thiệu.....	19
2.5.2 Các tính năng của MongoDB	19
2.6 MongoDB Atlas	20
2.6.1 Giới thiệu về MongoDB Atlas	20
2.6.2 Kiến trúc và mô hình triển khai	20
CHƯƠNG 3: PHƯƠNG PHÁP THỰC NGHIỆM.....	21
3.1 Phương pháp thu thập dữ liệu	21
3.1.1 Khởi tạo kết nối hệ thống.....	21
3.1.2 Điều phối thu thập đa mục tiêu	22
3.1.3 Trích xuất danh sách	24
3.1.4 Thu thập thông tin chi tiết	24
3.1.5 Lưu trữ dữ liệu MongoDB Atlas	25
3.2 Mô tả dữ liệu	26
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM.....	30
4.1 Giới thiệu	30
4.2 Kết quả thu thập dữ liệu	30
4.3 Truy vấn dữ liệu	31
4.4 Phân tích dữ liệu bất động sản	35
CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ.....	47
5.1. Kết luận.....	47
5.2. Hạn chế của đề tài	47
5.3. Kiến nghị và Hướng phát triển	47
TÀI LIỆU THAM KHẢO	49

DANH SÁCH BẢNG

Bảng 3.1: Bảng mô tả các biến và kiểu dữ liệu.....	27
Bảng 3.2: Thông tin mô tả bảng dự án (project_info)	27
Bảng 3.3: Thông tin mô tả bảng đặc điểm (spec)	28
Bảng 3.4: Thông tin mô tả bảng người môi giới (contact_info)	29

DANH SÁCH HÌNH ẢNH, BIỂU ĐỒ

Hình 3.1: Đoạn mã dùng để khởi tạo trình duyệt Chrome	21
Hình 3.2: Đoạn mã dùng để kết nối đến MongoDB Atlas	22
Hình 3.3: Cấu hình trong file config.yaml	23
Hình 3.4: Đoạn mã dùng để duyệt qua từng trang của từng loại giao dịch	23
Hình 3.5: Đoạn mã dùng để lấy danh sách các đường dẫn trong trang.....	24
Hình 3.6: Đoạn mã dùng để lấy các thông tin tin bất động sản	25
Hình 3.7: Cấu trúc dữ liệu được lưu trữ trên MongoDB	26
Hình 4.1: Tổng quan dữ liệu được lưu trữ trên MongoDB Atlas	30
Hình 4.2: Tìm tất cả các bất động sản thuộc loại Villa/Townhouse	31
Hình 4.3: Tìm các bài đăng tin bán nhà ở Hải Phòng	31
Hình 4.4: Tìm nhà đất có hơn 3 phòng vệ sinh	32
Hình 4.5: Tìm bài đăng nhà có ban công hướng Bắc	32
Hình 4.6: Dự án có nhiều tin đăng nhất.....	33
Hình 4.7: Những bài đăng có nhiều hơn 24 hình ảnh	33
Hình 4.8: Tìm các tin đăng sau ngày 01/12/2025	33
Hình 4.9: Top 5 dự án có nhiều tin đăng	34
Hình 4.10: Đếm tổng số tin theo loại tin	34
Hình 4.11: Tìm những tin thuộc Apartment và có hướng Đông-Bắc	34
Hình 4.12: Thống kê mật độ tin theo khu vực	35
Hình 4.13: Đoạn mã dùng để kết nối và lấy dữ liệu về DataFrame	35
Hình 4.14: Mô tả tổng quan về dữ liệu trong DataFrame.....	36
Hình 4.15: Chia nhóm dữ liệu bất động sản thành hai phân khúc chính.....	37
Hình 4.16: Đoạn mã dùng để tách địa chỉ.....	37
Hình 4.17: Đoạn mã dùng để chuyển đổi cột price từ kiểu string sang float (sale).....	38
Hình 4.18: Đoạn mã dùng để chuyển đổi cột price từ kiểu string sang float (rent).....	38
Hình 4.19: Đoạn mã dùng để lấy top 5 loại hình bất động sản phổ biến nhất.....	39
Hình 4.20: Biểu đồ cơ cấu phân khúc bất động sản	40
Hình 4.21: Phân phối giá trên m ² ở các quận/huyện tại Tp.Hồ Chí Minh.....	41
Hình 4.22: Phân phối giá ở các quận/huyện tại Hà Nội	41

Hình 4.23: Phân bố hướng nhà và mặt bằng giá trung vị	42
Hình 4.24: Phân phối giá thuê dưới 50 triệu VND	43
Hình 4.25: Phân phối giá thuê bán dưới 20 tỷ VND	43
Hình 4.26: Top 10 dự án nổi bật với số lượng tin và giá trung bình.....	44
Hình 4.27: Top 10 đặc trưng có tương quan cao nhất với tổng giá bất động sản.....	44
Hình 4.28: Bản đồ nhiệt phân bố tin đăng bất động sản tại Việt Nam.....	46

CHƯƠNG 1: TỔNG QUAN

1.1 Giới thiệu đề tài

Trong bối cảnh chuyển đổi số, dữ liệu đóng vai trò quan trọng trong nhiều lĩnh vực, đặc biệt bất động sản là nơi các tin đăng mua bán, cho thuê được cập nhật liên tục trên các nền tảng trực tuyến. Các website bất động sản không chỉ kết nối người mua và người bán mà còn phản ánh xu hướng thị trường, mức giá và đặc điểm bất động sản theo khu vực.

Trong đó, batdongsan.com.vn là một nền tảng lớn và uy tín tại Việt Nam, cung cấp khối lượng dữ liệu phong phú nhưng việc khai thác tự động gấp nhiều khó khăn do cấu trúc phức tạp và nội dung tải động. Xuất phát từ thực tế này, đề tài được thực hiện nhằm xây dựng một hệ thống thu thập và lưu trữ dữ liệu bất động sản tự động, phục vụ cho các hoạt động phân tích sau này.

1.2 Nhiệm vụ của đề tài

Nhiệm vụ của đề tài “Thu thập và lưu trữ dữ liệu bất động sản từ website batdongsan.com.vn sử dụng Selenium và MongoDB” là nghiên cứu cách thức hoạt động của các công cụ thu thập dữ liệu web, đặc biệt là Selenium, từ đó xây dựng chương trình thu thập dữ liệu bất động sản từ website batdongsan.com.vn một cách tự động và hiệu quả.

Bên cạnh đó, đề tài tiến hành phân tích cấu trúc HTML của website, trích xuất các thông tin quan trọng của tin đăng bất động sản như tiêu đề, giá bán, diện tích, địa chỉ, đặc điểm kỹ thuật, thông tin dự án và người đăng tin. Dữ liệu sau khi thu thập sẽ được làm sạch, chuẩn hóa và lưu trữ trong cơ sở dữ liệu MongoDB để phục vụ cho việc phân tích và khai thác dữ liệu.

1.2.1 Tính cấp thiết của đề tài

Hiện nay, thị trường bất động sản có sự biến động lớn về giá cả, loại hình và phân bố theo khu vực. Việc nắm bắt thông tin thị trường kịp thời và chính xác là nhu cầu thiết yếu đối với các nhà đầu tư, doanh nghiệp bất động sản cũng như các nhà

nghiên cứu. Tuy nhiên, dữ liệu bất động sản thường phân tán, cập nhật liên tục và khó tổng hợp nếu thu thập thủ công.

Website batdongsan.com.vn chứa một lượng lớn dữ liệu giá trị nhưng không cung cấp sẵn các công cụ trích xuất dữ liệu cho mục đích nghiên cứu. Việc thu thập dữ liệu tự động gặp nhiều khó khăn do website sử dụng nội dung tải động và các biện pháp hạn chế truy cập tự động. Vì vậy, cần có giải pháp kỹ thuật phù hợp để thu thập dữ liệu hiệu quả.

Selenium là công cụ mạnh mẽ cho phép mô phỏng hành vi người dùng trên trình duyệt, có khả năng xử lý các trang web động. Khi kết hợp Selenium với các thư viện phân tích HTML và cơ sở dữ liệu MongoDB, có thể xây dựng một hệ thống thu thập và lưu trữ dữ liệu bất động sản có tính linh hoạt, mở rộng và phù hợp với dữ liệu phi cấu trúc.

Do đó, việc nghiên cứu và ứng dụng Selenium trong thu thập dữ liệu bất động sản từ batdongsan.com.vn là cần thiết, mang tính thực tiễn cao và phù hợp với xu hướng ứng dụng khoa học dữ liệu hiện nay.

1.2.2 Ý nghĩa khoa học và thực tiễn của đề tài

Đề tài góp phần mở rộng kiến thức về lĩnh vực thu thập dữ liệu web, đặc biệt là đối với các website có nội dung tải động và cấu trúc phức tạp như các nền tảng bất động sản. Nghiên cứu giúp làm rõ cách thức kết hợp Selenium với các thư viện xử lý dữ liệu trong Python và cơ sở dữ liệu MongoDB để xây dựng một hệ thống thu thập dữ liệu hoàn chỉnh. Kết quả của đề tài có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu liên quan đến khoa học dữ liệu và khai phá dữ liệu web.

Ý nghĩa thực tiễn: Về mặt thực tiễn, đề tài cung cấp giải pháp tự động hóa việc thu thập dữ liệu bất động sản, giúp tiết kiệm thời gian và công sức so với phương pháp thu thập thủ công. Dữ liệu thu thập được có thể được sử dụng để phân tích giá bất động sản, đánh giá xu hướng thị trường, hỗ trợ ra quyết định đầu tư và nghiên cứu thị trường. Ngoài ra, hệ thống có thể mở rộng để thu thập dữ liệu theo thời gian thực hoặc tích hợp vào các bài toán phân tích và dự đoán trong tương lai.

1.3 Mục tiêu

1.3.1 Mục tiêu tổng quát

Đề tài “Thu thập và lưu trữ dữ liệu bất động sản từ website batdongsan.com.vn sử dụng Selenium và MongoDB” nhằm xây dựng một hệ thống thu thập dữ liệu bất động sản tự động, có khả năng xử lý nội dung động, chuẩn hóa dữ liệu và lưu trữ hiệu quả, từ đó tạo tiền đề cho các hoạt động phân tích và khai thác dữ liệu bất động sản.

1.3.2 Mục tiêu cụ thể

Phân tích cấu trúc website batdongsan.com.vn và xác định các thành phần dữ liệu cần thu thập. Xây dựng chương trình thu thập dữ liệu bất động sản sử dụng Selenium. Trích xuất các thông tin quan trọng của tin đăng bất động sản như giá, diện tích, địa chỉ, đặc điểm kỹ thuật và thông tin người đăng. Làm sạch và chuẩn hóa dữ liệu thu thập được. Lưu trữ dữ liệu vào cơ sở dữ liệu MongoDB để phục vụ cho việc truy vấn và phân tích.

1.4 Đối tượng và phạm vi

1.4.1 Đối tượng

Đối tượng nghiên cứu của đề tài là các công cụ và kỹ thuật thu thập dữ liệu web, cụ thể là Selenium trong Python, cùng với cơ sở dữ liệu MongoDB và dữ liệu bất động sản được công bố trên website batdongsan.com.vn.

1.4.2 Phạm vi

Đề tài tập trung vào việc thu thập dữ liệu các tin đăng mua bán và cho thuê bất động sản trên website batdongsan.com.vn. Phạm vi nghiên cứu chỉ giới hạn trong việc thu thập, làm sạch và lưu trữ dữ liệu, trực quan, không đi sâu vào các mô hình phân tích hay dự đoán giá bất động sản.

1.5 Phương pháp nghiên cứu

1.5.1 Phương pháp nghiên cứu tài liệu

Thu thập và nghiên cứu các tài liệu liên quan đến web scraping, Selenium, Python và MongoDB nhằm xây dựng cơ sở lý thuyết cho đề tài.

1.5.2 Phương pháp phân tích trang

Phân tích cấu trúc HTML và các thành phần tải động của website batdongsan.com.vn để xác định các dữ liệu cần trích xuất.

1.5.3 Phương pháp thực nghiệm

Xây dựng và thử nghiệm chương trình thu thập dữ liệu bất động sản bằng Selenium, đánh giá khả năng thu thập dữ liệu trong điều kiện thực tế.

1.5.4 Phương pháp kết hợp công cụ

Kết hợp Selenium với các thư viện BeautifulSoup xử lý dữ liệu và MongoDB nhằm đảm bảo việc thu thập, lưu trữ và quản lý dữ liệu hiệu quả.

1.5.5 Phương pháp đánh giá và phân tích dữ liệu

Đánh giá chất lượng, tính đầy đủ và độ chính xác của dữ liệu thu thập được sau quá trình làm sạch và lưu trữ.

1.6 Những đóng góp nghiên cứu của đề tài

1.6.1 Trong lĩnh vực học thuật

Đề tài đóng góp vào việc nghiên cứu và ứng dụng các kỹ thuật thu thập dữ liệu web trong lĩnh vực khoa học dữ liệu. Kết quả nghiên cứu giúp làm rõ cách xây dựng hệ thống thu thập dữ liệu cho các website có nội dung động và cấu trúc phức tạp, đồng thời cung cấp tài liệu tham khảo cho các nghiên cứu liên quan. tài liệu tham khảo hữu ích cho các nghiên cứu sau này trong lĩnh vực này.

1.6.2 Trong thực tiễn

Về mặt thực tiễn, đề tài cung cấp một giải pháp khả thi cho việc thu thập và lưu trữ dữ liệu bất động sản tại Việt Nam. Hệ thống có thể được sử dụng để hỗ trợ phân tích thị trường, nghiên cứu xu hướng giá và phục vụ cho các ứng dụng thực tế trong lĩnh vực bất động sản.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Trích xuất dữ liệu web

2.1.1 Định nghĩa

Web scraping là quá trình trích xuất dữ liệu từ các trang web một cách tự động thông qua các chương trình hoặc kịch bản phần mềm [1]. Python được sử dụng rộng rãi cho web scraping nhờ cú pháp dễ hiểu và các thư viện mạnh mẽ như BeautifulSoup và Selenium [2], [3], giúp trích xuất dữ liệu hiệu quả hơn so với sao chép thủ công. Quá trình web scraping thường bao gồm việc gửi yêu cầu đến máy chủ, tải về mã nguồn HTML và bóc tách dữ liệu cần thiết để lưu trữ, dựa trên nguyên lý kiến trúc REST của hệ thống web [4]. Khi thu thập dữ liệu từ web, cần xem xét các yếu tố pháp lý và đạo đức, đặc biệt là chính sách robots.txt và điều khoản sử dụng của trang web mục tiêu [5].

2.1.2 Quy trình hoạt động

Quy trình web scraping cơ bản bao gồm các bước sau [7]:

- Xác định mục tiêu như là URL và cấu trúc dữ liệu cần thu thập.
- Sử dụng giao thức HTTP để lấy mã nguồn HTML/CSS/JS từ máy chủ
- Phân tích cú pháp HTML để hiểu cấu trúc của mã nguồn, tìm kiếm các thẻ HTML, lớp, ID...
- Trích xuất dữ liệu bằng cách sử dụng các bộ chọn như XPath hoặc CSS selector để xác định và lấy nội dung mong muốn.
- Làm sạch dữ liệu thô và lưu trữ vào định dạng có cấu trúc như bảng tính, JSON, CSV hoặc cơ sở dữ liệu.

2.2 Selenium

2.2.1 Giới thiệu

Selenium là một framework mã nguồn mở dùng để tự động hóa trình duyệt web, cho phép mô phỏng hành vi người dùng như nhấp chuột, nhập liệu và điều hướng trang web [6]. Hỗ trợ nhiều trình duyệt như Chrome, Firefox, Edge..., đồng thời tích hợp liền mạch với các ngôn ngữ lập trình như Python, Java, C# và JavaScript. Đặc biệt, Selenium rất mạnh trong việc xử lý các trang web có nội dung tải động bằng JavaScript [9].

2.2.2 Bộ công cụ selenium

Bộ công cụ Selenium bao gồm:

- Selenium WebDriver: Công cụ chính để điều khiển trình duyệt thông qua mã lập trình, thực hiện các thao tác nhấp chuột, nhập văn bản, điều hướng trang và mô phỏng các hành động của người dùng.
- Selenium IDE: Trình duyệt để ghi lại các thao tác và tự động tạo kịch bản kiểm thử.
- Selenium Grid: Chạy thử nghiệm trên nhiều trình duyệt và hệ thống cùng lúc để kiểm thử tương thích đa trình duyệt.

2.3 Beautiful Soup

2.3.1 Giới thiệu

Beautiful Soup là một thư viện Python dùng để trích xuất dữ liệu từ các tệp HTML và XML. Chức năng cốt lõi của nó là cung cấp các phương thức điều hướng, tiềm kiếm và sửa đổi cây phân tích cú pháp một cách tự nhiên, giúp tiết kiệm thời gian viết mã cho lập trình viên [8].

2.3.2 Kiến trúc và bộ phân tích cú pháp

Beautiful Soup không tự thực hiện việc phân tích cú pháp mà cung cấp giao diện để làm việc với các thư viện phân tích cú pháp khác, hỗ trợ các parser sau:

- html.parser: Bộ phân tích tiêu chuẩn đi kèm với Python. Ưu điểm là tính ổn định và không yêu cầu cài đặt phụ thuộc bên ngoài.
- lxml: Bộ phân tích cú pháp XML/HTML viết bằng C. Một số tài liệu đánh giá lxml có tốc độ xử lý rất nhanh, đây là parser được khuyến nghị sử dụng trong môi trường sản phẩm.
- html5lib: Phân tích tài liệu HTML giống hệt cách trình duyệt web hoạt động. Parser này cực kỳ mạnh mẽ trong việc xử lý HTML bị lỗi nặng nhưng có tốc độ chậm hơn lxml.

2.3.3 Các đối tượng chính

Trong quá trình phân tích tài liệu HTML, BeautifulSoup chuyển đổi mã nguồn thành các đối tượng Python. Tài liệu phân loại 4 đối tượng chính quan trọng trong cấu trúc dữ liệu của thư viện:

- Tag: Tương ứng với một thẻ HTML hoặc XML trong tài liệu gốc. Đối tượng Tag sở hữu các thuộc tính quan trọng như name và attrs từ điển chứa các thuộc tính như class, id, href.
- NavigableString: Biểu diễn văn bản chứa bên trong một thẻ. Đây là chuỗi Unicode và là dữ liệu thực tế mà quá trình Web Scaping thường hướng tới.
- BeautifulSoup: Đối tượng đại diện cho toàn bộ tài liệu được phân tích.
- Comment: Đối tượng đặc biệt để xử lý các phần chú thích trong HTML.

2.3.4 Xử lý mã hóa

Xử lý mã hóa là tự động phát hiện và chuyển đổi bảng mã. BeautifulSoup tự động chuyển đổi tài liệu đầu vào sang Unicode và tài liệu đầu ra sang UTF-8. Điều này giải quyết vấn đề hiển thị sai ký tự thường gặp khi thu thập dữ liệu tiếng việt từ các trang web cũ hoặc có cấu hình server không chuẩn [10].

2.4 Cơ sở dữ liệu NoSQL

2.4.1 Giới thiệu

Cơ sở dữ liệu NoSQL được thiết kế để lưu trữ dữ liệu theo các mô hình linh hoạt, hỗ trợ khả năng mở rộng và hiệu năng cao cho các ứng dụng hiện đại [10]. Ngoài

ra, cơ sở dữ liệu NoSQL được công nhận rộng rãi vì khả năng dễ phát triển, chức năng cũng như hiệu năng ở quy mô lớn. NoSQL đặc biệt phù hợp với dữ liệu phi cấu trúc và bán cấu trúc, đồng thời được công nhận rộng rãi trong các hệ thống quy mô lớn [11].

2.4.2 *Ưu điểm của cơ sở dữ liệu NoSQL*

Ưu điểm:

- Cung cấp các sơ đồ linh hoạt giúp công đoạn phát triển nhanh hơn và có khả năng lặp lại cao hơn lựa chọn lý tưởng cho dữ liệu phi cấu trúc hoặc dữ liệu bán cấu trúc [12].
- Khả năng mở rộng bằng cách phân tán dữ liệu trên nhiều máy chủ và thường được cung cấp dưới dạng dịch vụ đám mây được quản lý.
- Được tối ưu cho từng mô hình dữ liệu cụ thể nên cho hiệu suất và truy vấn cao hơn so với cơ sở dữ liệu quan hệ trong nhiều trường hợp [13].
- Cung cấp các API và kiểu dữ liệu cực kỳ thiết thực được xây dựng riêng cho từng mô hình dữ liệu tương ứng.

2.4.3 *Các trường hợp sử dụng cơ sở dữ liệu NoSQL*

Quản lý dữ liệu theo thời gian thực: NoSQL hỗ trợ xử lý dữ liệu nhanh và theo thời gian thực, cung cấp các tính năng như đề xuất cá nhân hóa, danh sách xem và tiếp tục xem. Nhờ khả năng mở rộng cao, NoSQL được sử dụng để phục vụ hàng trăm triệu người dùng cùng lúc, điển hình như các nền tảng xem phim trực tuyến.

Bảo mật trên nền tảng đám mây: NoSQL dạng đồ thị cho phép phân tích nhanh các mối quan hệ phức tạp trong dữ liệu, từ đó phát hiện và xử lý rủi ro bảo mật. Loại cơ sở dữ liệu này đặc biệt phù hợp cho các hệ thống giám sát an ninh và quản lý rủi ro trên môi trường đám mây.

Các ứng dụng có độ sẵn sàng cao: NoSQL phân tán rất phù hợp để xây dựng các ứng dụng yêu cầu độ trễ thấp và tính sẵn sàng cao như mạng xã hội, nhắn tin, chia sẻ tệp. Nhờ khả năng mở rộng và xử lý song song, giúp hệ thống hoạt động ổn định hơn.

NoSQL được ứng dụng rộng rãi trong các hệ thống thời gian thực, nền tảng đám mây và các ứng dụng yêu cầu độ sẵn sàng cao như mạng xã hội và thương mại điện tử [14].

2.5 MongoDB

2.5.1 Giới thiệu

Mongo là một hệ quản trị cơ sở dữ liệu thuộc loại NoSQL, được thiết kế để lưu trữ và xử lý dữ liệu dung lượng lớn với hiệu suất cao.

Khác với cơ sở dữ liệu quan hệ sử dụng bảng và hàng, MongoDB lưu trữ dữ liệu dưới dạng các tài liệu theo cặp khóa và giá trị, được tổ chức trong các tập hợp. Nhờ mô hình dữ liệu linh hoạt, MongoDB cho phép lưu trữ dữ liệu phi cấu trúc và bán cấu trúc một cách hiệu quả. Mô hình này giúp tổ chức dữ liệu linh hoạt và dễ mở rộng theo chiều ngang [15].

Đồng thời hỗ trợ các chức năng như truy vấn nhanh, lập chỉ mục, tổng hợp dữ liệu và mở rộng hệ thống dễ dàng trên nhiều máy chủ. MongoDB cũng hỗ trợ nhiều ngôn ngữ lập trình như Python, Java, C#, Go và Ruby.

2.5.2 Các tính năng của MongoDB

MongoDB cung cấp các tính năng nổi bật như:

- Sao chép dữ liệu: thông qua bộ sao chép nhằm đảm bảo tính sẵn sàng cao cho hệ thống. Trong đó, một máy chủ chính xử lý các thao tác đọc và ghi, các máy chủ lưu trữ bản sao dữ liệu và sẵn sàng thay thế khi máy chủ chính gặp sự cố. Đảm bảo tính sẵn sàng cao thông qua Replica Sets [16].
- Khả năng mở rộng theo 2 chiều: Mở rộng theo chiều dọc, tăng cấu hình cho một máy chủ. Mở rộng theo chiều ngang, bổ sung thêm nhiều máy chủ vào hệ thống để chia tải.
- Cân bằng tải: tự động cân bằng tải giữa các máy chủ thông qua cơ chế mở rộng và phân tán dữ liệu, phân mảnh dữ liệu để cân bằng tải và mở rộng hệ thống [17].
- Không cần lược đồ cố định: MongoDB là cơ sở dữ liệu không cần lược đồ cố định, cho phép thay đổi cấu trúc dữ liệu linh hoạt trong quá trình lưu trữ và xử lý.

- Mô hình lưu trữ dữ liệu: Được lưu trữ dưới dạng các tài liệu gồm các cặp khóa-giá trị, thay vì hàng và cột như trong SQL, giúp dữ liệu linh hoạt và dễ mở rộng.

2.6 MongoDB Atlas

2.6.1 Giới thiệu về MongoDB Atlas

MongoDB Atlas là dịch vụ cơ sở dữ liệu NoSQL dạng đám mây do MongoDB Inc. phát triển, cho phép triển khai, quản lý và vận hành cơ sở dữ liệu MongoDB mà không cần cài đặt và duy trì hạ tầng máy chủ cục bộ [18]. Dịch vụ này hỗ trợ triển khai trên các nền tảng điện toán đám mây phổ biến như Amazon Web Services (AWS), Google Cloud Platform (GCP) và Microsoft Azure.

MongoDB Atlas kế thừa đầy đủ các đặc điểm cốt lõi của MongoDB, bao gồm mô hình dữ liệu hướng tài liệu, khả năng lưu trữ dữ liệu phi cấu trúc và hỗ trợ truy vấn linh hoạt. Nhờ các đặc điểm này, MongoDB Atlas phù hợp với các hệ thống xử lý dữ liệu lớn và các ứng dụng yêu cầu khả năng mở rộng cao.

2.6.2 Kiến trúc và mô hình triển khai

MongoDB Atlas được triển khai dưới dạng các cụm cơ sở dữ liệu trên nền tảng đám mây. Mỗi cluster bao gồm nhiều node đảm nhiệm các vai trò khác nhau nhằm đảm bảo tính sẵn sàng, khả năng sao lưu và độ tin cậy của hệ thống. MongoDB Atlas hỗ trợ cơ chế sao lưu tự động, giám sát hiệu năng và bảo mật kết nối thông qua các giao thức mã hóa giúp tối ưu hóa khả năng truy cập và giảm thiểu chi phí quản lý vận hành.

Người dùng có thể kết nối đến MongoDB Atlas thông qua chuỗi kết nối được cung cấp sẵn, cho phép các ứng dụng bên ngoài truy cập cơ sở dữ liệu một cách thuận tiện. Mô hình triển khai này giúp tách biệt rõ ràng giữa tầng ứng dụng và tầng lưu trữ dữ liệu, từ đó nâng cao tính linh hoạt và khả năng mở rộng của hệ thống.

Dữ liệu bất động sản có đặc trưng là số lượng lớn, cấu trúc không đồng nhất và thường xuyên thay đổi, do đó việc sử dụng cơ sở dữ liệu NoSQL như MongoDB Atlas là phù hợp. Việc triển khai MongoDB Atlas trên nền tảng đám mây giúp hệ thống giảm thiểu công sức quản lý hạ tầng, đồng thời cho phép truy cập dữ liệu linh hoạt từ nhiều môi trường khác nhau.

CHƯƠNG 3: PHƯƠNG PHÁP THỰC NGHIỆM

3.1 Phương pháp thu thập dữ liệu

Công việc thu thập dữ liệu về tin thuê bán nhà đất từ web batdongsan.vn được tiến hành thực hiện bằng việc sử dụng công cụ Selenium để truy cập đến từng trang tin bất động sản và dùng BeautifulSoup để trích xuất các thông tin. Sau đó tiến hành lưu trữ thông tin đã được thu thập đến cơ sở dữ liệu MongoDB Atlas. Quá trình này được thực hiện theo các bước sau:

3.1.1 Khởi tạo kết nối hệ thống

Để hạn chế việc khả năng bị phát hiện bởi các cơ chế chống bot của website, thư viện undetected_chromedriver (UC) dùng để khởi tạo và điều khiển trình duyệt Chrome được sử dụng trong bài toán này.

```
def init_browser(headless=True):
    logger.info("Initializing driver...")
    options = uc.ChromeOptions()
    if headless:
        options.add_argument("--headless=new")
        options.add_argument("--start-maximized")
        options.add_argument("--disable-gpu")
        options.add_argument("--disable-dev-shm-usage")
        options.add_argument("--no-sandbox")
        options.add_argument("--disable-extensions")
        user_agent = (
            "Mozilla/5.0 (Windows NT 10.0; Win64; x64) "
            "AppleWebKit/537.36 (KHTML, like Gecko) "
            "Chrome/120.0.0.0 Safari/537.36"
        )
        options.add_argument(f"--user-agent={user_agent}")
    try:
        driver = uc.Chrome(options=options)
        driver.set_page_load_timeout(60)
        return driver
    except Exception as e:
        logger.error(f"Failed to initialize driver: {e}")
        raise
```

Hình 3.1: Đoạn mã dùng để khởi tạo trình duyệt Chrome

Sau đó tạo client kết nối đến tới MongoDB Atlas thông qua chuỗi kết nối (URI) được bảo mật trong tệp biến môi trường .env.

```
class MongoDBClient:  
    def __init__(self):  
        user = os.getenv("MONGO_USER")  
        pw = os.getenv("MONGO_PASS")  
        cluster = os.getenv("MONGO_CLUSTER")  
        db_name = os.getenv("MONGO_DB")  
        col_name = os.getenv("MONGO_COLLECTION")  
        uri = f"mongodb+srv://{{user}}:{{pw}}@{{cluster}}/?retryWrites=true&w=majority"  
  
        try:  
            self.client = MongoClient(uri, serverSelectionTimeoutMS=5000)  
            self.client.server_info()  
            self.db = self.client[db_name]  
            self.col = self.db[col_name]  
            self.col.create_index(  
                keys: [("post_id", 1), ("transaction_type", 1)],  
                unique=True  
            )  
            logger.info(f"Connected to Atlas: DB [{db_name}] | Collection [{col_name}]")  
  
        except Exception as e:  
            logger.error(f"MongoDB connection failed: {e}")  
            raise
```

Hình 3.2: Đoạn mã dùng để kết nối đến MongoDB Atlas

3.1.2 Điều phối thu thập đa mục tiêu

Trên trang batdongsan.com.vn, có 2 mục tiêu chính được chọn ra để thu thập dữ liệu:

- Nhà đất bán: <https://batdongsan.com.vn/nha-dat-ban>
- Nhà đất cho thuê: <https://batdongsan.com.vn/nha-dat-cho-thue>

```

scraper:
  headless: true

targets:
  - name: "nha_dat_ban"
    url: "https://batdongsan.com.vn/nha-dat-ban"
    start_page: 1
    end_page: 2
    enabled: true
  - name: "nha_dat_cho_thue"
    url: "https://batdongsan.com.vn/nha-dat-cho-thue"
    start_page: 1
    end_page: 2
    enabled: true

```

Hình 3.3: Cấu hình trong file config.yaml

Việc cấu hình targets có trong file config.yaml, giúp điều hướng luân phiên dễ dàng tới các URL loại giao dịch bất động sản. Mỗi một mục tiêu trong danh sách, chương trình tự động xác định phạm vi thu thập dựa trên tham số start_page và end_page. Sử dụng Selenium WebDriver chạy qua các trang tiếp theo của mỗi loại bằng cách nối hậu tố /p{ số_trang }.

```

def process_multiple_pages(driver, target, mongo_client):
    name = target.get("name")
    base_url = target.get("url")
    start_page = target.get("start_page", 1)
    end_page = target.get("end_page", 2)

    total_new = 0

    for p in range(start_page, end_page + 1):
        page_url = base_url if p == 1 else f"{base_url}/p{p}"

        links = fetch_list_links(driver, page_url,
                               mongo_client)

        if not links:
            continue

        inserted_count = process_single_page(driver, links,
                                              mongo_client)

        time.sleep(random.uniform(3, 6))

    return total_new

```

Hình 3.4: Đoạn mã dùng để duyệt qua từng trang của từng loại giao dịch

3.1.3 Trích xuất danh sách

Tại mỗi trang danh sách đã được xác định, chương trình thực hiện nhận diện các đường dẫn của tin bất động sản có trong trang đó. Sau đó thu thập các URL vào một danh sách, chương trình trích xuất id của từng tin thông qua URL, kiểm tra xem id này có nằm trong cơ sở dữ liệu MongoDB Alas nhằm đảm bảo khi chạy nhiều lần sẽ không bị trùng lặp tin.

```
def fetch_list_links(driver, page_url, mongo_client):
    links = []

    driver.get(page_url)
    wait = WebDriverWait(driver, 15)
    wait.until(EC.presence_of_element_located((By.CLASS_NAME, "js_card")))
    items = driver.find_elements(By.CLASS_NAME, "js_card")
    type_post = classify_transaction_type(page_url)

    for item in items:
        try:
            link_tag = item.find_element(By.TAG_NAME, "a")
            url = link_tag.get_attribute("href")
            pid = get_post_id(url)

            if pid and not mongo_client.check_duplicated(pid, type_post):
                links.append((url, pid))

        except (NoSuchElementException, StaleElementReferenceException):
            continue

    return links
```

Hình 3.5: Đoạn mã dùng để lấy danh sách các đường dẫn trong trang

3.1.4 Thu thập thông tin chi tiết

Sử dụng Selenium WebDriver để truy cập lần lượt các URL bài đăng và thu thập mã nguồn HTML của từng trang. Áp dụng các cơ chế chờ để đảm bảo các thành phần quan trọng của trang được hiển thị đầy đủ trước khi tiến hành trích xuất dữ liệu. Sau khi trang được tải hoàn tất, mã HTML được trích xuất và phân tích bằng thư viện BeautifulSoup nhằm thu thập các thông tin chi tiết của bất động , bao gồm: tiêu đề bài đăng, giá bán, diện tích, địa chỉ, mô tả chi tiết, đặc điểm bất động sản và các thông tin liên quan khác.

```

def parse_detail_page(html_content, url):
    post_id = get_post_id(url)
    soup = BeautifulSoup(html_content, "lxml")
    title = get_text(soup, "h1")
    address = get_text(soup, "span.re_pr-short-description")
    price_per_spm = get_text(soup, "span.ext")
    description = get_description(soup)
    images = get_images(soup)
    coords = get_coordinate(html_content)
    project_info = get_project_info(soup)
    agent_info = get_agent_info(soup)
    sub_info = get_sub_info(soup)
    specs = get_specs(soup)

    spec_data = {}
    for key, value in specs.items():
        mapped_key = SPEC_KEY_MAPPING.get(key, key)
        if mapped_key not in ['price', 'area']:
            spec_data[mapped_key] = value
    verified_tag = soup.find("div", class_="re_pr-stick-listing-verified")
    verified = "verified" if verified_tag else "unverified"

    data = {
        "post_id": post_id,
        "property_url": url,
        "transaction_type": classify_transaction_type(url),
        "property_category": classify_property_type(url),
        "title": title,
        "address": address,
        "latitude": coords.get('latitude'),
        "longitude": coords.get('longitude'),
        "price": specs.get("khoang_gia"),
        "price_per_spm": price_per_spm,
        "area": specs.get("dien_tich"),
        "spec": spec_data,
        "description": description,
        "images": images,
        "project_info": project_info,
        "date_posted": sub_info.get("ngay_dang"),
        "date_expired": sub_info.get("ngay_het_han"),
        "news_type": sub_info.get("loai_tin"),
        "contact_info": agent_info,
        "verified_status": verified,
        "scraped_at": datetime.now().isoformat()
    }
    return data

```

Hình 3.6: Đoạn mã dùng để lấy các thông tin tin bất động sản

3.1.5 Lưu trữ dữ liệu MongoDB Atlas

Sau khi dữ liệu đã được bóc tách, toàn bộ thông tin được đóng gói dưới dạng một đối tượng để đẩy lên MongoDB Atlas. Đây là cở sở dữ liệu NoSQL dựa trên đám mây, giúp hệ thống có khả năng mở rộng tốt và lưu trữ linh hoạt các dữ liệu không cấu trúc từ website.

```

_id: ObjectId('694e1769179cd17f57a900ec')
post_id : "44743692"
property_url : "https://batdongsan.com.vn/ban-can-ho-chung-cu-phuong-an-phu-prj-master.."
transaction_type : "sale"
property_category : "Apartment"
title : "Quá Đẳng Cấp! Sở hữu view triệu đô tại Masteri Park Place CT5 - Sinh l..."
address : "Masteri Park Place, Phường An Phú, Quận 2, Hồ Chí Minh"
latitude : 10.8059150792259
longitude : 106.771332375044
price : "5,9 tỷ"
price_per_spm : "~103,51 triệu/m²"
area : "57 m²"
▶ spec : Object
  description : "Chính thức nhận booking 100 triệu/suất (có hoàn lại) ~ Khách booking s..."
▶ images : Array (25)
▶ project_info : Object
  date_posted : "22/12/2025"
  date_expired : "29/12/2025"
  news_type : "Tin VIP Kim Cương"
▶ contact_info : Object
  verified : false
  scraped_at : "2025-12-23T19:14:29.874609"

```

Hình 3.7: Cấu trúc dữ liệu được lưu trữ trên MongoDB

3.2 Mô tả dữ liệu

Tên biến	Mô tả	Kiểu dữ liệu
post_id	ID của bài đăng	string
property_url	Đường dẫn bài đăng	string
property_category	Loại bất động sản	string
transaction_type	Loại giao dịch	string
title	Tiêu đề	string
address	Địa chỉ	string
latitude	Vĩ độ	float
longitude	Kinh độ	float
price	Giá cả	string
price_per_spm	Đơn giá trên mỗi m ²	string
area	Diện tích	string

description	Nội dung mô tả	string
images	Danh sách hình ảnh	array
date_posted	Ngày đăng	date
date_expired	Ngày hết hạn	date
news_type	Loại tin tức	string
verified_status	Tình trạng tin xác thực	string
spec	Chứa thông tin đặc điểm bất động sản	object
contact_info	Chứa thông tin môi giới	object
project_info	Chứa thông tin dự án	object

Bảng 3.1: Bảng mô tả các biến và kiểu dữ liệu

Tên biến	Mô tả	Kiểu dữ liệu
name	Tên dự án	string
status	Tình trạng dự án	string
price	Khoảng giá	string
investor	Nhà đầu tư	string
image	URL hình ảnh dự án	string
project_url	URL dự án	string
listing_count	Số tin bất động sản có trong dự án	int

Bảng 3.2: Thông tin mô tả bảng dự án (project_info)

Tên biến	Mô tả	Kiểu dữ liệu
bedroom	Số phòng ngủ	string
bathroom	Số phòng vệ sinh	string
num_floor	Số tầng	string
orientation	Hướng nhà	string
balcony_direction	Hướng ban công	string
front_width	Chiều rộng mặt tiền	string
road_width	Chiều dài đường vào	string
legal	Pháp lý	string
furniture	Nội thất	string
exdate	Thời gian dự kiến vào ở	string
electricity	Thỏa thuận chi phí điện	string
water	Thỏa thuận chi phí nước	string
internet	Thỏa thuận chi phí internet	string
utilities	Tiện ích	string

Bảng 3.3: Thông tin mô tả bảng đặc điểm (spec)

Tên biến	Mô tả	Kiểu dữ liệu
name	Tên môi giới	string
profile_url	URL môi giới	string
avartar_url	URL hình ảnh môi giới	string
phone_invisible	Số điện thoại	string
zalo_url	URL zalo môi giới	string
join_duration	Thời gian tham gia	string
listings	Số tin đang có	int

Bảng 3.4: Thông tin mô tả bảng người môi giới (contact_info)

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM


4.1 Giới thiệu

Trong phần này, những kết quả đã đạt được từ việc áp dụng công cụ Selenium để thu thập dữ liệu từ website batdongsan.com.vn sẽ được mô tả chi tiết trong phần này.

4.2 Kết quả thu thập dữ liệu

Sau khi hoàn thành quá trình thu thập, tổng cộn dữ liệu đã thu được khoảng 32.794 bản ghi thông tin bài đăng bất động sản. Dữ liệu này bao gồm đa dạng các loại hình từ nhà đất bán đến nhà đất cho thuê.

- Tổng số bản ghi: 32.794 tin đăng
- Tổng số giờ cho chạy thực tế: 46 tiếng
- Thời gian thu thập trung bình mỗi bài là 5 giây/1 tin
- Tỷ lệ trích xuất thành công: ~98% (Một số ít tin đăng bị lỗi do cấu trúc HTML)
- Dung lượng lưu trữ xấp xỉ 47MB dữ liệu văn bản thuần khi đã được nén



Hình 4.1: Tổng quan dữ liệu được lưu trữ trên MongoDB Atlas

4.3 Truy vấn dữ liệu

```
>_MONGOSH
> db.properties_post.find(
  { property_category: "Villa/Townhouse" },
  { _id: 0, title: 1, area: 1, price: 1 }
)
< [
  {
    title: 'Quý hàng đợt cuối chiết khấu 18%, tặng xe điện VF8/VF9 Vinhomes Đan Phượng, LH:0937 996 ***',
    price: '15,6 tỷ',
    area: '184 m2'
  },
  {
    title: 'Bán nhà biệt thự tại Swan Bay, 23.2 tỷ VND, 320m2 - Zone 4.3 : LH:0909 165 ***',
    price: '23,2 tỷ',
    area: '320 m2'
  },
  {
    title: 'TỔNG HỢP CÁC CĂN BIỆT THỰ SONG LẬP, ĐƠN LẬP, CĂN GÓC VỊ TRÍ ĐẸP, GIÁ TỐT TẠI VINHOMES OCEAN PARK 2',
    price: '17,6 tỷ',
    area: '120 m2'
  },
  {
    title: 'CHIẾT KHẤU 20-25%, QUÝ CĂN ĐẸP VÀ RẺ NHẤT DỰ ÁN, NỘP 30% NHẬN NHÀ. LIÊN HỆ:0942 906 ***XEM DỰ ÁN ẢI',
    price: '17,4 tỷ',
    area: '120 m2'
  },
  {
    title: 'Duy nhất căn Liên Kề TV2BSP-08 Shop Vinhomes Cố Loa 75m2 2 mặt tiền rẻ nhất DA chỉ 15 tỷ CK 10%',
    price: '18 tỷ',
    area: '75 m2'
  },
  {
    title: 'Suất ngoại giao chiết khấu 18% villas rừng song lập, đơn lập, shophouse. CDT Ecopark',
    price: '16 tỷ',
    area: '220 m2'
  }
]
```

Hình 4.2: Tìm tất cả các bất động sản thuộc loại Villa/Townhouse

```
>_MONGOSH
> db.properties_post.find(
  { address: /Hải Phòng/ },
  { _id: 0, title: 1, address: 1, price: 1 }
)
< [
  {
    title: 'Vinhomes Dương Kinh (240ha) giá F1 - 5 tỷ 4 tầng, vị trí vàng, chiết khấu sâu, quà tặng không',
    address: 'Dự án Vinhomes Golden City, Phường Hòa Nghĩa, Dương Kinh, Hải Phòng',
    price: '5 tỷ'
  },
  {
    title: 'Giá hàng mới Vin Dương Kinh giá tốt nhất từ 4,9 tỷ tặng VF3, chiết khấu trực tiếp từ PKD Chủ đầu tư',
    address: 'Vinhomes Golden City, Phường Hòa Nghĩa, Dương Kinh, Hải Phòng',
    price: '4,9 tỷ'
  },
  {
    title: 'Sở Hữu Nhà Vườn Đặc Biệt - Sóng Xanh Sóng Đẳng Cấp Tại Biệt Thự Liền Kề Emerald Symphony',
    address: 'Emerald Symphony, Hoa Động, Thủy Nguyên, Hải Phòng',
    price: 'Thỏa thuận'
  },
  {
    title: 'Quý căn giá tốt nhất - Dự án của Doji Land: Emerald Symphony',
    address: 'Emerald Symphony, Hoa Động, Thủy Nguyên, Hải Phòng',
    price: '9,8 tỷ'
  },
  {
    title: 'CHUYÊN NHƯỢNG CĂN HỘ MINATO RẺ NHẤT DỰ ÁN - CÓ SẴN HỢP ĐỒNG THUÊ LÂU DÀI',
    address: 'The Minato Residence, Vĩnh Niệm, Lê Chân, Hải Phòng',
    price: '2,6 tỷ'
  },
  {
    title: 'Chính chủ bán lô đất 2 mặt ngõ dt 826m2 Hòa Bình, Thủy Nguyên. Giá 15tr/m2',
    address: 'Phường Hòa Bình, Thủy Nguyên, Hải Phòng',
    price: '15 triệu/m2'
  },
  {
    title: 'Bán Shophouse Hoàng Huy New City, 17 tỷ VND, 96m2, hàng hiếm tại Thủy Nguyên, Hải Phòng',
    address: 'Hoàng Huy New City, Phường Diên Đức, Thủy Nguyên, Hải Phòng'
  }
]
```

Hình 4.3: Tìm các bài đăng tin bán nhà ở Hải Phòng

```
>_MONGOSH
> db.properties_post.find(
  { "spec.bathroom": /3|4|5/ },
  { _id: 0, title: 1, "spec.bathroom": 1 }
)
< [
  {
    title: 'Shophouse Vin Cố Loa CDT CK 22%-33% từ 15.8 tỷ HTLS 2 năm, 2MT, đường lớn, gần công viên, chung cư',
    spec: {
      bathroom: '5 phòng'
    }
  }
  {
    title: 'Duy nhất căn Liền kề TV2BSP-88 Shop Vinhomes Cố Loa 75m2 2 mặt tiền rẻ nhất DA chỉ 15 tỷ CK 19%',
    spec: {
      bathroom: '5 phòng'
    }
  }
  {
    title: 'Suất ngoại giao chiết khấu 18% villas riêng lẻ, đơn lập, shophouse. CDT Ecopark',
    spec: {
      bathroom: '5 phòng'
    }
  }
  {
    title: 'Nhà riêng tại Hưng Long, Long Thượng, Căn Giuộc, Long An, giá siêu hời chỉ với 1,86 tỷ, 50m2',
    spec: {
      bathroom: '3 phòng'
    }
  }
  {
    title: 'Siêu phẩm liền kề xé khe San Hồ Vinhomes Ocean Park 2, 98m2, Đông Nam, giá 13,4 tỷ, kinh doanh đỉnh',
    spec: {
      bathroom: '5 phòng'
    }
  }
]
```

Hình 4.4: Tìm nhà đất có hơn 3 phòng vệ sinh

```
>_MONGOSH
> db.properties_post.find(
  { "spec.balcony_direction": "Bắc" },
  { _id: 0, title: 1, "spec.balcony_direction": 1 }
)
< [
  {
    title: 'Nhà riêng tại Hưng Long, Long Thượng, Căn Giuộc, Long An, giá siêu hời chỉ với 1,86 tỷ, 50m2',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
  {
    title: 'Bán căn skylinked villa- 3PN+ 1, 2WC (198,2m2), giá bán 13.000tỷ. Căn hộ xe hơi chạy lên tận nhà',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
  {
    title: 'Capital Square, căn hộ view sông ngay cầu sông Hàn, cạnh Vincom. Mở bán đợt đầu chiết khấu đến 17%',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
  {
    title: 'Nam Long mở bán căn hộ ven sông Mizuki Park, liền kề Phú Mỹ Hưng',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
  {
    title: 'Cập nhật giá hàng T12/2025 giá tốt nhà phố & biệt thự Vinhomes Grand Park, siêu phẩm view sông',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
  {
    title: 'Quỹ 200 căn chuyển nhượng 1PN, 2PN, 3PN, 4PN giá tốt nhất thị trường - Hỗ trợ lãi suất 0% 30 tháng',
    spec: {
      balcony_direction: 'Bắc'
    }
  }
]
```

Hình 4.5: Tìm bài đăng nhà có ban công hướng Bắc

```
>_MONGOSH
    }
}
Type "it" for more
> db.properties_post.find(
  { "project_info.listing_count": { $gt: 50 } },
  { _id: 0, title: 1, "project_info.listing_count": 1 }
).sort({ "project_info.listing_count": -1 })
< [
  {
    title: 'Lần đầu tiên CBT MIK Group mở bán chung cư cao cấp tại Vin Ocean Park 2 với mức giá cực hấp dẫn',
    project_info: {
      listing_count: 944
    }
  }
]
{
  title: 'Chính thức nhận booking chung cư cao cấp của CĐT MIK Group tại Vin Ocean Park 2',
  project_info: {
    listing_count: 944
  }
}
]
```

Hình 4.6: Dự án có nhiều tin đăng nhất

```
>_MONGOSH
> db.properties_post.find(
  { $expr: { $gte: [{ $size: "$images" }, 24] } },
  { _id: 0, title: 1 }
)
< [
  {
    title: 'Quá Đẳng Cấp! Sở hữu view triệu đô tại Masteri Park Place CTS - Sinh lời bền vững. Gọi 0902 999 ***'
  }
]
{
  title: 'CHIẾT KHẤU 20-25%, QUÝ CĂN ĐẸP VÀ RẺ NHẤT DỰ ÁN, NỘP 30% NHẬN NHÀ. LIÊN HỆ 0942 906 ***XEM DỰ ÁN A'
}
{
  title: 'Căn hộ 3PN Phú Đông Sky Garden "nhận nhà ở ngay - nhận sổ liền tay - giá tốt nhất thị trường"
}
{
  title: 'Căn góc Sonata hướng sông sát 2 tòa chung cư, thích hợp cho thuê, kinh doanh, buôn bán. CK 10%'
}
```

Hình 4.7: Những bài đăng có nhiều hơn 24 hình ảnh

```
>_MONGOSH
> db.properties_post.find(
  { date_posted: { $gt: "2025-12-01" } },
  { _id: 0, title: 1, date_posted: 1 }
)
< [
  {
    title: 'Quá Đẳng Cấp! Sở hữu view triệu đô tại Masteri Park Place CTS - Sinh lời bền vững. Gọi 0902 999 ***',
    date_posted: '22/12/2025'
  }
]
{
  title: 'Bán đất tại phố Hòa Bình, Thanh Miếu, Phú Thọ diện tích 264 m2',
  date_posted: '22/12/2025'
}
{
  title: 'Bán nhà biệt thự tại Swan Bay, 23.2 tỷ VND, 320m2 - Zone 4.3 : LH:0909 165 ***',
  date_posted: '23/12/2025'
}
{
  title: 'GREEN SKYLINE CĂN HỘ XÂY XONG MỚI BÁN HIỆM HƠI GIÁ TỪ 3 TỶ LH0939 720 ***',
  date_posted: '23/12/2025'
}
{
  title: 'Chủ bán kín! Nhà đẹp 5 tầng khu Vip Công Lã, 4mX20m, hẻm 8m có lửng, chỉ 9.5 tỷ TL',
  date_posted: '23/12/2025'
}
{
  title: 'TỔNG HỢP CÁC CĂN BIỆT THỰ SONG LẬP, ĐÔN LẬP, CĂN GÓC VỊ TRÍ ĐẸP, GIÁ TỐT TẠI VINHOMES OCEAN PARK 2',
  date_posted: '22/12/2025'
}
{
  title: 'Shophouse Vin Cố Loa CBT CK 22%-33% từ 15.8 tỷ HTLS 2 năm, 2MT, đường lớn, gần công viên, chung cư',
  date_posted: '23/12/2025'
}
{
  title: 'CHIẾT KHẤU 20-25%, QUÝ CĂN ĐẸP VÀ RẺ NHẤT DỰ ÁN, NỘP 30% NHẬN NHÀ. LIÊN HỆ 0942 906 ***XEM DỰ ÁN A',
  date_posted: '22/12/2025'
}
```

Hình 4.8: Tìm các tin đăng sau ngày 01/12/2025

```
> db.properties_post.aggregate([
  { $group: { _id: "$project_info.name", total: { $sum: 1 } } },
  { $sort: { total: -1 } },
  { $limit: 5 }
])
< [
  {
    _id: null,
    total: 17622
  }
]
{
  _id: 'Vinhomes Golden River Ba Son',
  total: 148
}
{
  _id: 'Vinhomes Ocean Park 2',
  total: 140
}
{
  _id: 'Vinhomes Ocean Park Gia Lâm',
  total: 122
}
{
  _id: 'Vinhomes Central Park',
  total: 97
}
```

Hình 4.9: Top 5 dự án có nhiều tin đăng

```
> db.properties_post.aggregate([
  { $group: { _id: "$news_type", total: { $sum: 1 } } }
])
< [
  {
    _id: 'Tin VIP Vàng',
    total: 2412
  }
]
{
  _id: 'Tin thường',
  total: 21904
}
{
  _id: 'Tin VIP Bạc',
  total: 7328
}
{
  _id: 'Tin VIP Kim Cương',
  total: 1150
}
```

Hình 4.10: Đếm tổng số tin theo loại tin

```
>.MONGOISH
> db.properties_post.find(
  {
    $and: [
      { property_category: "Apartment" },
      { "spec.orientation": "Đông - Bắc" }
    ]
  },
  { _id: 0, title: 1 }
)
< [
  {
    title: 'Căn Hộ Trung Tâm Thuận An, Giá Rẻ Nhất Thị Trường, 80% Căn Hộ Dưới 35tr/m2, Thanh Toán 0,5%/tháng'
  }
]
{
  title: 'Full giờ hàng 1PN đến 4PN, loft, penthouse, Metropole Thủ Thiêm giá tốt nhất thị trường'
}
{
  title: 'Quý căn độc quyền giai đoạn 1 dự án Alumi Aluvia, CK 12%, quà tặng 200 triệu'
}
{
  title: 'Rõ hàng 47m2 - 55m2 Bcons Newsky độc quyền từ chủ đầu tư Bcons dành cho khách hàng đăng ký sớm'
}
{
  title: 'Rõ hàng MT Eastmark City- Giá 3,3tỷ, 65m2, 1PN, 1WC, - Mua trực tiếp từ Chủ Đầu Tư'
}
{
  title: 'GIÁ RẺ NHẤT THỊ TRƯỜNG - CĂN HỘ VINHOMES 2PN CHỈ 2TY730'
}
{
  title: 'GIÒ HÀNG "ĐỘC QUYỀN" BCONS NEWSKY GIÁ GỐC CĐT - SÂN CĂN ĐẸP 47 - 55 - 65 - 75 - 99m2'
}
{
  title: '[BÁN CĂN HỘ GIA ĐÌNH 2PN] MẶT TIỀN GẦM ĐẦY ĐỦ TIỆN ÍCH-DỘI DIỆN NHÀ GA METRO-GIÁ GỐC CHỦ ĐẦU TƯ'
}
{
  title: 'Bán gấp căn 3PN - 80.1m2, 7.8 tỷ, view hồ, tòa B Masteri West Heights - Smart City Tây Hồ'
}
```

Hình 4.11: Tìm những tin thuộc Apartment và có hướng Đông-Bắc

```

>_MONGOSH
> db.properties_post.aggregate([
  {
    $project: {
      district: {
        $arrayElemAt: [{ $split: ["$address", " "], -2}]
      }
    }
  },
  {
    $group: {
      _id: "$district",
      total: { $sum: 1 }
    }
  },
  { $sort: { total: -1 } }
])
< [
  {
    _id: 'Quận 2',
    total: 2112
  },
  {
    _id: 'Quận 7',
    total: 1358
  },
  {
    _id: 'Cầu Giấy',
    total: 1338
  },
  {
    _id: 'Nam Từ Liêm',
    total: 1318
  },
  {
    _id: 'Bình Thạnh',
    total: 1271
  }
]

```

Hình 4.12: Thống kê mật độ tin theo khu vực

4.4 Phân tích dữ liệu bất động sản

Tiến hành kết nối đến MongoDB Atlas để lấy dữ liệu về đưa vào DataFrame

```

import sys
from pathlib import Path
import pandas as pd
import os
from dotenv import load_dotenv
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import re
from pymongo import MongoClient

PROJECT_ROOT = Path.cwd().parent
sys.path.append(str(PROJECT_ROOT))
load_dotenv(dotenv_path=os.path.abspath("../.env"))

user = os.getenv("MONGO_USER")
pw = os.getenv("MONGO_PASS")
cluster = os.getenv("MONGO_CLUSTER")
db_name = os.getenv("MONGO_DB")
col_name = os.getenv("MONGO_COLLECTION")

uri =
f"mongodb+srv://{{user}}:{{pw}}@{{cluster}}/?retryWrites=true&w=
majority"

client = MongoClient(uri)
db = client[db_name]
col = db[col_name]
data = list(col.find({}, {"_id": 0}))

df = pd.DataFrame(data)
df = pd.json_normalize(data, sep=".")
```

Hình 4.13: Đoạn mã dùng để kết nối và lấy dữ liệu về DataFrame


```

Index: 31661 entries, 0 to 32792
Data columns (total 47 columns):
 #   Column           Non-Null Count Dtype  
 ---  -- 
 0   post_id          31661 non-null  object  
 1   property_url     31661 non-null  object  
 2   transaction_type 31661 non-null  object  
 3   property_category 31661 non-null  object  
 4   title             31661 non-null  object  
 5   address            31661 non-null  object  
 6   latitude           31661 non-null  float64 
 7   longitude          31661 non-null  float64 
 8   price              31660 non-null  object  
 9   price_per_spm      20442 non-null  object  
 10  area               31661 non-null  object  
 11  description         31661 non-null  object  
 12  images              31660 non-null  object  
 13  date_posted        31661 non-null  datetime 
 14  date_expired       31661 non-null  datetime 
 15  news_type           31661 non-null  object  
 16  verified            26117 non-null  object  
 17  scraped_at          31661 non-null  object  
 18  spec.bedroom         18655 non-null  object  
 19  spec.bathroom        18357 non-null  object  
 20  spec.legal            16185 non-null  object  
 21  spec.furniture        17101 non-null  object  
 22  project_info.name    14354 non-null  object  
 23  project_info.status   14352 non-null  object  
 24  project_info.investor 14354 non-null  object  
 25  project_info.image    14354 non-null  object  
 26  project_info.project_url 14354 non-null  object  
 27  project_info.listing_count 14354 non-null  float64 
 28  contact_info.name     31657 non-null  object  
 29  contact_info.profile_url 31657 non-null  object  
 30  contact_info.avatar_url 29530 non-null  object  
 31  contact_info.phone_invisible 31661 non-null  object  
 32  contact_info.zalo_url    31661 non-null  object  
 33  contact_info.join_duration 13203 non-null  object  
 34  contact_info.listings     13203 non-null  object  
 35  spec.front_width        11081 non-null  object  
 36  spec.road_width          9327 non-null  object  
 37  spec.num_floor           9674 non-null  object  
 38  project_info.price       7972 non-null  object  
 39  spec.orientation         8685 non-null  object  
 40  spec.balcony_direction   5995 non-null  object  
 41  spec.exdate              3246 non-null  object  
 42  spec.electricity          2696 non-null  object  
 43  spec.water                2606 non-null  object  
 44  spec.internet              1882 non-null  object  
 45  spec.utilities            3500 non-null  object  
 46  verified_status           5544 non-null  object  
dtypes: datetime64[ns](2), float64(3), object(42)

```

Hình 4.14: Mô tả tổng quan về dữ liệu trong DataFrame

Để làm rõ bức tranh toàn cảnh và nắm bắt các xu hướng đặc thù của thị trường, chúng tôi tiến hành tách nhóm dữ liệu bất động sản thành hai phân khúc chính: cho thuê (rent) và mua bán (sale). Việc tách biệt này không chỉ giúp nhận diện các loại hình sản phẩm phô biến mà còn cho phép so sánh sự khác biệt rõ rệt về mục đích sử dụng, hành vi khách hàng và giá trị đầu tư giữa hai thị trường.



Hình 4.15: Chia nhóm dữ liệu bất động sản thành hai phân khúc chính

Nhằm nâng cao chất lượng phân tích dữ liệu, các cột Price và Address được tiến hành chuẩn hóa như sau:

```
def split_address(addr):
    if pd.isna(addr): return None, None, None
    parts = [p.strip() for p in str(addr).split(',')]
    province = parts[-1] if len(parts) >= 1 else None
    district = parts[-2] if len(parts) >= 2 else None
    ward = parts[-3] if len(parts) >= 3 else None
    return ward, district, province

df[['ward', 'district', 'province']] =
df['address'].apply(lambda x: pd.Series(split_address(x)))
```

Hình 4.16: Đoạn mã dùng để tách địa chỉ

```

def convert_price_sale(x):
    if pd.isna(x): return np.nan, "valid"
    text = str(x).lower().strip().replace(",", ".")
    if "thỏa thuận" in text: return np.nan, "negotiable"

    try:
        match = re.search(r"(\d+\.\?\d*)", text)
        if not match or "/m" in text: return np.nan,
    "error"

        num = float(match.group(1))
        if "tỷ" in text: return num * 1000, "valid"
        if "triệu" in text: return num, "valid"
        return num, "valid"
    except:
        return np.nan, "error"

res_sale = df_sale["price"].apply(convert_price_sale)
df_sale["price"] = [x[0] for x in res_sale]
df_sale["price_status"] = [x[1] for x in res_sale]

df_sale = df_sale[df_sale["price_status"] != "error"].drop(columns=["price_status"])

```

Hình 4.17: Đoạn mã dùng để chuyển đổi cột price từ kiểu string sang float (sale)

```

def convert_price_rent(x):
    if pd.isna(x): return np.nan, "valid"
    text = str(x).lower().strip().replace(",", ".")
    if "thỏa thuận" in text: return np.nan, "negotiable"

    try:
        match = re.findall(r"(\d+\.\?\d*)", text)
        if not match: return np.nan, "error"

        return float(match[0]), "valid"
    except:
        return np.nan, "error"

res_rent = df_rent["price"].apply(convert_price_rent)
df_rent["price"] = [x[0] for x in res_rent]
df_rent["price_status"] = [x[1] for x in res_rent]

df_rent = df_rent[df_rent["price_status"] != "error"].drop(columns=["price_status"])

```

Hình 4.18: Đoạn mã dùng để chuyển đổi cột price từ kiểu string sang float (rent)

```

def get_category_counts(df, top_n=5):
    counts = df['property_category'].value_counts()
    if len(counts) > top_n:
        top_counts = counts[:top_n]
        others_count = counts[top_n:].sum()
        top_counts['Khác'] = others_count
        return top_counts
    return counts

rent_categories = get_category_counts(df_rent)
sale_categories = get_category_counts(df_sale)

colors = plt.get_cmap('Pastell').colors

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(18, 8))
fig.suptitle('CƠ CẤU PHÂN KHÚC BẤT ĐỘNG SẢN', fontsize=20,
fontweight='bold', y=1.05)

ax1.pie(rent_categories, labels=rent_categories.index,
autopct='%.1f%%',
        startangle=140, colors=colors,
wedgeprops={'edgecolor': 'white', 'linewidth': 2})
ax1.set_title('Thị trường CHO THUÊ', fontsize=15,
fontweight='bold', pad=20)


ax2.pie(sale_categories, labels=sale_categories.index,
autopct='%.1f%%',
        startangle=140, colors=colors,
wedgeprops={'edgecolor': 'white', 'linewidth': 2})
ax2.set_title('Thị trường MUA BÁN', fontsize=15,
fontweight='bold', pad=20)

plt.tight_layout()
plt.show()

```

Hình 4.19: Đoạn mã dùng để lấy top 5 loại hình bất động sản phổ biến nhất

Bắt đầu quá trình phân tích:




Hình 4.20: Biểu đồ cơ cấu phân khúc bất động sản

Nhận xét biểu đồ cơ cấu phân khúc bất động sản:


- Phân khúc căn hộ (Apartment) đang xu thế dẫn đầu ở cả hai thị trường bán và thuê lần lượt là 33.3% và 29.8%.
- Nhà riêng (Private House) chiếm tỉ trọng 24.6% lớn thứ hai trong loại giao dịch mua, điều này phản ánh tâm lý người dân rất thích sở hữu nhà riêng ngược lại bên cho thuê thì chủ yếu tập trung phân khúc nhà mặt phố (Storefront House) phục vụ chủ yếu cho mục đích kinh doanh, thương mại.
- Ta thấy rõ rệt phân khúc biệt thự (Villa/Townhouse) bên mua bán là 11.9% nhưng lại không nằm trong nhóm chính bên cho thuê. Điều này cho thấy biệt thự chủ yếu là tài sản giá trị cao dùng để đầu tư dài hạn hoặc định cư, ít phổ biến tại trong thị trường cho thuê.

PHÂN PHỐI GIÁ TẠI HỒ CHÍ MINH



Hình 4.21: Phân phối giá trên m² ở các quận/huyện tại Tp.Hồ Chí Minh


PHÂN PHỐI GIÁ TẠI HÀ NỘI



Hình 4.22: Phân phối giá ở các quận/huyện tại Hà Nội

So sánh hai biểu đồ phân bố giá trên m² ở các quận/huyện tại TP.HCM và Hà Nội:

- Hà Nội có mức giá tràn cao hơn TP.HCM, trong khi TP.HCM có phân bố giá trải rộng đều hơn ở nhiều quận.
- Cả hai thành phố đều thể hiện xu hướng: giá giảm dần từ khu vực trung tâm ra ngoại thành.
- Sự hiện diện của nhiều giá trị ngoại lai cho thấy thị trường bất động sản ở cả hai đô thị đều có mức độ phân hóa cao.




Hình 4.23: Phân bố hướng nhà và mặt bằng giá trung vị

Nhận xét phân bố hướng nhà:


- Hướng Đông Nam có số lượng bất động sản nhiều nhất đồng thời giá trung bình cao, cho thấy đây là hướng được ưa chuộng.
- Các hướng Tây Bắc và Đông Bắc cũng có mức giá tương đối cao.
- Nhìn chung, biểu đồ cho thấy hướng nhà có ảnh hưởng nhất định đến giá bất động sản.

PHÂN PHỐI GIÁ THUÊ (Dưới 50 triệu)




Hình 4.24: Phân phối giá thuê dưới 50 triệu VND


PHÂN PHỐI GIÁ BÁN (Dưới 20 tỷ)



Hình 4.25: Phân phối giá thuê bán dưới 20 tỷ VND




Hình 4.26: Top 10 dự án nổi bật với số lượng tin và giá trung bình



Hình 4.27: Top 10 đặc trưng có tương quan cao nhất với tổng giá bất động sản

Nhận xét:

- Về mối quan hệ giữa số lượng tin và giá bất động sản: Các dự án lớn như Vinhomes Ocean Park và Vinhomes Smart City có số lượng tin đăng cao, phản ánh mức độ quan tâm lớn của thị trường; tuy nhiên, các dự án có giá trung bình cao không nhất thiết đi kèm với số lượng tin đăng lớn, cho thấy sự phân hóa rõ rệt giữa tính thanh khoản và mức giá của từng dự án.
- Về mức độ ảnh hưởng của các đặc trưng đến giá: Giá trên mỗi mét vuông (price_per_spm) là yếu tố tác động mạnh nhất đến tổng giá bất động sản, tiếp theo là số phòng ngủ và số phòng tắm. Các đặc trưng về kích thước mặt tiền và độ rộng đường cũng có ảnh hưởng đáng kể, trong khi một số đặc trưng khác như mức độ xác thực tin đăng thể hiện tác động không rõ rệt.



Hình 4.28: Bản đồ nhiệt phân bố tin đăng bất động sản tại Việt Nam

Nhận xét:

Tin đăng bất động sản tập trung chủ yếu tại các đô thị lớn như Hà Nội, TP. Hồ Chí Minh và các tỉnh ven biển, phản ánh xu hướng đô thị hóa mạnh mẽ và sự chênh lệch đáng kể về mức độ sôi động của thị trường giữa các khu vực.

CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ

5.1. Kết luận

Sau một thời gian tập trung nghiên cứu và trực tiếp sử dụng các công cụ mã nguồn mở để thu thập dữ liệu và lưu trữ, đội tài đã hoàn thành các mục tiêu đề ra ban đầu, đạt được những kết quả như sau:

Về kỹ thuật thu thập dữ liệu, bộ công cụ crawler đã được xây dựng thành công dựa trên Selenium kết hợp với Undetected Chromedriver. Nhờ vào áp dụng những thư viện vào chương trình python đã vận hành ổn định nhờ cơ chế giả lập hành vi người dùng thông qua việc ngẫu nhiên hóa thời gian chờ giữa các thao tác truy cập.

Việc tích hợp BeautifulSoup vào module parser đã thực hiện hiệu quả việc bóc tách và trích xuất các trường thông tin phức tạp từ mã HTML thô.

Mô hình lưu trữ đã triển khai thành công lên nền tảng điện toán đám mây MongoDB Atlas. Việc thiết lập Compound Index giúp giải quyết hiệu quả vấn đề trùng lặp dữ liệu, đảm bảo tính toàn vẹn, nhất quán và duy nhất của kho dữ liệu thu thập được.

5.2. Hạn chế của đội tài

Do cơ chế bóc tách dựa trên cây DOM, hệ thống sẽ gặp khó khăn nếu website mục tiêu thay đổi cấu trúc thẻ HTML hoặc thiết kế lại giao diện. Khi đó, module parser cần phải được cập nhật thủ công để thích ứng.

Để ưu tiên tính an toàn và không bị chặn địa chỉ IP, thiết lập cài đặt cần phải tạo các khoảng nghỉ giữa mỗi lần truy cập. Chính sự thận trọng này vô tình làm giới hạn tốc độ thu thập khi cần xử lý một lượng dữ liệu khổng lồ trong thời gian ngắn.

5.3. Kiến nghị và Hướng phát triển

Để dự án thực sự hoàn thiện và cải thiện hơn trong tương lai, chúng tôi đề xuất một số hướng phát triển sau:

Sử dụng danh sách proxy xoay vòng kết hợp với các giải thuật đa luồng hoặc đa tiến trình sẽ giúp tăng đáng kể tốc độ thu thập dữ liệu, đồng thời vẫn đảm bảo an toàn và hạn chế nguy cơ bị chặn từ phía website mục tiêu.

Xây dựng dashboard trực quan hóa dữ liệu. Phát triển một giao diện web cho phép hiển thị các biểu đồ phân tích như biến động giá theo khu vực, mật độ tin đăng bất động sản hoặc bản đồ nhiệt dựa trên dữ liệu tọa độ GPS đã thu thập, từ đó hỗ trợ người dùng trong việc phân tích và ra quyết định.

TÀI LIỆU THAM KHẢO

- [1] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2018.
- [2] S. Munzert, C. Rubba, P. Meißner and D. Nyhuis, *Automated Data Collection with R: A Practical Guide to Web Scraping and Text Mining*, Chichester: Wiley, 2015.
- [3] M. Grinberg, *Flask Web Development: Developing Web Applications with Python*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2018.
- [4] R. T. Fielding, "Architectural styles and the design of network-based software architectures" Ph.D. dissertation, Dept. Inf. and Comput. Sci., Univ. of California, Irvine, CA, 2000.
- [5] V. Krotov and J. Silva, "Legality and Ethics of Web Scraping" *Communications of the Association for Information Systems*, vol. 47, no. 1, p. 1–28, 2020.
- [6] U. Gundecha, *Selenium Testing Tools Cookbook*, 2nd ed. Packt Publishing, 2016.
- [7] A. Mesbah and A. van Deursen, "Invariant-based Automatic Testing of AJAX User Interfaces" *IEEE Transactions on Software Engineering*, vol. 38, no. 1, p. 210–229, 2012.
- [8] S. Bradshaw, E. Brazil and K. Chodorow, *MongoDB: The Definitive Guide*, 3rd ed. Sebastopol, CA: O'Reilly Media, 2019.
- [9] P. J. Sadalage and M. Fowler, *NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence*, Boston, MA: Addison-Wesley, 2012.
- [10] R. Cattell, "Scalable SQL and NoSQL Data Stores" *ACM SIGMOD Record*, vol. 39, no. 4, p. 12–27, 2011.
- [11] D. J. Abadi, "Consistency Tradeoffs in Modern Distributed Database System Design," *IEEE Computer*, vol. 45, no. 2, p. 37–42, 2012.
- [12] MongoDB Inc., *MongoDB Manual*, 2025. [Online]. Available: <https://www.mongodb.com/docs/manual/>. [Accessed 2025].

- [13] L. Richardson, *Beautiful Soup Documentation*, 2025. [Online]. Available: <https://www.crummy.com/software/BeautifulSoup/>. [Accessed 2025].
- [14] SeleniumHQ, *Selenium WebDriver Documentation*, 2025. [Online]. Available: <https://www.selenium.dev>. [Accessed 2025].
- [15] K. Banker, *MongoDB in Action*, 2nd ed. Shelter Island, NY: Manning Publications, 2016.
- [16] MongoDB Inc., Replication, 2025. [Online]. Available: <https://www.mongodb.com/docs/manual/replication/>. [Accessed 2025].
- [17] MongoDB Inc., Sharding, 2025. [Online]. Available: <https://www.mongodb.com/docs/manual/sharding/>. [Accessed 2025].
- [18] MongoDB Inc., MongoDB Atlas Architecture, 2025. [Online]. Available: <https://www.mongodb.com/docs/atlas/architecture/>. [Accessed 2025].

PHỤ LỤC 1

```
from bs4 import BeautifulSoup
import re
import unidecode
from urllib.parse import urlparse
from datetime import datetime

SALE_PROPERTY_TYPES = {
    "ban-can-ho-chung-cu": "Apartment",
    "ban-can-ho-chung-cu-mini": "Mini Apartment",
    "ban-nha-rieng": "Private House",
    "ban-nha-biet-thu-lien-ke": "Villa/Townhouse",
    "ban-nha-mat-pho": "Storefront House",
    "ban-shophouse-nha-pho-thuong-mai": "Shophouse",
    "ban-dat-nen-du-an": "Project Land",
    "ban-dat": "Land Plot",
    "ban-trang-trai-khu-nghi-duong": "Farm/Resort",
    "ban-condotel": "Condotel",
    "ban-kho-nha-xuong": "Warehouse/Factory"
}

RENT_PROPERTY_TYPES = {
    "cho-thue-can-ho-chung-cu": "Apartment",
    "cho-thue-can-ho-chung-cu-mini": "Mini Apartment",
    "cho-thue-nha-rieng": "Private House",
    "cho-thue-nha-biet-thu-lien-ke": "Villa/Townhouse",
    "cho-thue-nha-mat-pho": "Storefront House",
    "cho-thue-shophouse-nha-pho-thuong-mai": "Shophouse",
    "cho-thue-dat": "Land Plot",
    "cho-thue-trang-trai-khu-nghi-duong": "Farm/Resort",
    "cho-thue-condotel": "Condotel",
    "cho-thue-kho-nha-xuong": "Warehouse/Factory",
    "cho-thue-van-phong": "Office Space",
    "cho-thue-cua-hang-ki-ot": "Shop/Kiosk",
    "cho-thue-phong-tro": "Room"
}

ALL_PROPERTY_TYPES = {**SALE_PROPERTY_TYPES,
                      **RENT_PROPERTY_TYPES}

TRANSACTION_TYPE_PATTERNS = {
    "sale": r'^ban-',
    "rent": r'^cho-thue-'
}
```

```

SPEC_KEY_MAPPING = {
    "khoang_gia": "price",
    "dien_tich": "area",
    "so_phong_ngu": "bedroom",
    "so_phong_tam_ve_sinh": "bathroom",
    "so_tang": "num_floor",
    "huong_nha": "orientation",
    "huong_ban_cong": "balcony_direction",
    "mat_tien": "front_width",
    "duong_vao": "road_width",
    "phap_ly": "legal",
    "noi_that": "furniture",
    "thoi_gian_du_kien_vao_o": "exdate",
    "muc_gia_dien": "electricity",
    "muc_gia_nuoc": "water",
    "muc_gia_internet": "internet",
    "tien_icnh": "utilities"
}

def normalize_key(key):
    key = unidecode.unidecode(key).lower()
    key = re.sub(r'[\s,]+', '_', key)
    key = re.sub(r'[^w_]', '_', key)
    key = re.sub(r'_+', '_', key)
    return key.strip('_')

def remove_empty_fields(data):
    cleaned = {}
    for key, value in data.items():
        if value is None:
            continue
        if isinstance(value, str) and not value.strip():
            continue
        if isinstance(value, dict):
            cleaned_nested = remove_empty_fields(value)
            if cleaned_nested:
                cleaned[key] = cleaned_nested
            continue
        if isinstance(value, list) and not value:
            continue
        cleaned[key] = value
    return cleaned

def get_text(soup, selector, default=None):
    if soup is None:
        return default
    tag = soup.select_one(selector)
    return tag.get_text(strip=True) if tag else default

POST_ID_PATTERN = re.compile(r"pr(\d+)$")
def get_post_id(url):
    match = POST_ID_PATTERN.search(url)
    return match.group(1) if match else None

```

```

def classify_property_type(url):
    path = urlparse(url).path.strip('/').lower()
    sorted_types = sorted(
        ALL_PROPERTY_TYPES.items(),
        key=lambda x: len(x[0]),
        reverse=True
    )
    for path_segment, category in sorted_types:
        if path.startswith(path_segment):
            is_full_match = len(path) == len(path_segment)
            if is_full_match or path[len(path_segment)] in ('-' or '+'):
                return category
    return "Unknown"

def classify_transaction_type(url):
    path = urlparse(url).path.strip('/').lower()
    for transaction_type, pattern in TRANSACTION_TYPE_PATTERNS.items():
        if re.match(pattern, path):
            return transaction_type
    return "Unknown"

def get_coordinate(html_content):
    geo = {}
    keys = ['latitude', 'longitude']
    for key in keys:
        pattern = rf'["\']?{re.escape(key)}["\']?\s*:\s*([-[\d\.\.]+)'
        match = re.search(pattern, html_content)
        if match:
            geo[key] = float(match.group(1).replace(' ', ''))

    return geo

def get_specs(soup):
    specs = {}
    for item in soup.select(".re_pr-specs-content-item"):
        label_tag = item.select_one(".re_pr-specs-content-item-title")
        value_tag = item.select_one(".re_pr-specs-content-item-value")
        if label_tag and value_tag:
            key =
            normalize_key(label_tag.get_text(strip=True))
            value = value_tag.get_text(strip=True)
            specs[key] = value
    return specs

def get_sub_info(soup):
    sub_info = {}
    for item in soup.select("div.re_pr-short-info-item"):
        title_tag = item.select_one("span.title")
        value_tag = item.select_one("span.value")
        if title_tag and value_tag:
            key =
            normalize_key(title_tag.get_text(strip=True))
            value = value_tag.get_text(strip=True)
            sub_info[key] = value
    return sub_info

```

```

def get_agent_info(soup):
    agent_info = {}
    contact_box = soup.find("div", class_="re_ldp-contact-box")
    agent_infor = contact_box.find("div", class_="re_agent-infor re_agent-name")
    if agent_infor:
        name_tag = (
            agent_infor.find("a", class_="re_contact-name") or
            agent_infor.find("a", class_="js_agent-contact-name"))
        if name_tag:
            agent_info['name'] = name_tag.get_text(strip=True)
            href = name_tag.get('href')
            if href:
                agent_info['profile_url'] = href
    avatar_tag = soup.select_one("img.re_contact-avatar")
    if avatar_tag:
        src = avatar_tag.get('src')
        if src:
            agent_info['avatar_url'] = src
    phone_tag = soup.select_one("div.js_phone")
    if phone_tag:
        phone_span = phone_tag.find('span')
        if phone_span:
            agent_info['phone_invisible'] =
            phone_span.get_text(strip=True)
    zalo_tag = soup.select_one("a.js_zalo-chat")
    if zalo_tag:
        data_href = zalo_tag.get('data-href')
        if data_href:
            agent_info['zalo_url'] = data_href
    other_agent_info = soup.select("div.re_agent-experiment
div.agent-deail-infor")
    for item in other_agent_info:
        label_tag = item.select_one("span")
        value_tag = item.select_one("i")
        if label_tag and value_tag:
            label = label_tag.get_text(strip=True).lower()
            value = value_tag.get_text(strip=True)
            if "tham gia" in label:
                agent_info["join_duration"] = value
            elif "tin đăng" in label:
                agent_info["listings"] = value
    return agent_info

```

```

def get_project_info(soup):
    project_info = {}
    card = soup.select_one("div.re_ldp-project-info")
    if not card:
        return project_info
    title = get_text(card, "div.re_project-title")
    if title:
        project_info["name"] = title
    for item in card.select("span.re_prj-card-config-value"):
        text = item.get_text(strip=True)
        aria_label = unidecode.unidecode(item.get("aria-label", "")).lower()
        if "trang thai" in aria_label:
            project_info["status"] = text
        elif "gia" in aria_label:
            project_info["price"] = text
    investor = get_text(card, "span.re_prj-card-config-value"
i.re_icon-office--sm + span.re_long-text")
    if investor:
        project_info["investor"] = investor
    img = card.select_one("div.re_section-avatar img")
    if img:
        src = img.get("src")
        if src:
            project_info["image"] = src
    link = card.select_one("div.re_section-avatar a")
    if link:
        href = link.get("href")
        if href:
            project_info["project_url"] = href
    a_tag = card.select_one("a.re_link-pr span")
    if a_tag:
        text = a_tag.get_text(strip=True)
        match = re.search(r'\d+', text.replace(',', '')) 
        if match:
            project_info["listing_count"] = int(match.group())
    return project_info

def get_description(soup):
    prefix = "Thông tin mô tả"
    description_tag = soup.select_one(".re_pr-description")
    description = description_tag.get_text(strip=True)
    if description.startswith(prefix):
        description = description[len(prefix):].strip()
    return description if description else None

def get_images(soup):
    images = []
    for item in soup.select("div.re_media-thumb-
item.js_media-thumbs-item"):
        img_tag = item.find("img")
        if img_tag:
            img_url = img_tag.get("data-src") or
img_tag.get("src")
            if img_url:
                images.append(img_url)
    return images

```

Phân phối giá của hai thành phố Hà Nội và Tp. Hồ Chí Minh

```
df_sale['province_clean'] = df_sale['province'].str.replace('Thành phố ', '').str.replace('TP. ', '').str.strip()

def plot_district_prices_fixed(city_name, ax, color_palette):
    city_df = df_sale[df_sale['province_clean'].str.contains(city_name, case=False, na=False)].copy()

    if city_df.empty:
        ax.set_title(f"Không có dữ liệu cho {city_name}")
        return

    district_counts = city_df['district'].value_counts()
    top_districts = district_counts[district_counts > 10].index
    city_df = city_df[city_df['district'].isin(top_districts)]

    order = city_df.groupby('district')['price_per_spm'].median().sort_values(ascending=False).index

    sns.boxplot(
        data=city_df,
        y='district',
        x='price_per_spm',
        order=order,
        ax=ax,
        palette=color_palette,
        fliersize=1
    )

    ax.set_xlim(0, city_df['price_per_spm'].quantile(0.95))
    ax.set_title(f'PHÂN PHỐI GIÁ TẠI {city_name.upper()}', fontsize=16, fontweight='bold', pad=15)
    ax.set_xlabel('Giá (Triệu VND/m2)', fontsize=12)
    ax.set_ylabel('', fontsize=12)
    ax.grid(axis='x', linestyle='--', alpha=0.6)
    fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(14, 20))

    plot_district_prices_fixed('Hà Nội', ax1, 'Reds')
    plot_district_prices_fixed('Hồ Chí Minh', ax2, 'Blues')

plt.tight_layout(pad=4.0)
plt.show()
```

Phân phối giá theo hướng nhà

```
import plotly.io as pio
pio.renderers.default = "browser"
import plotly.express as px

orientation_counts = df_sale['spec.orientation'].value_counts().reset_index()
orientation_counts.columns = ['Hướng', 'Số lượng']

orientation_price = df_sale.groupby('spec.orientation')['price_per_spm'].median().reset_index()
orientation_price.columns = ['Hướng', 'Giá trung vị/m2']

orientation_df = orientation_counts.merge(orientation_price, on='Hướng')

fig = px.bar_polar(orientation_df, r='Số lượng', theta='Hướng',
                    color='Giá trung vị/m2', template="plotly_white",
                    color_continuous_scale=px.colors.sequential.Reds,
                    title='PHÂN BỐ HƯỚNG NHÀ & MẶT BẰNG GIÁ (Màu đậm = Giá cao)')
fig.show()
```

Phân phối giá thuê và giá bán

```
def plot_dist_with_boxplot(data, title, color, unit):
    f, (ax_box, ax_hist) = plt.subplots(2, sharex=True,
                                        gridspec_kw={"height_ratios": (.15, .85)},
                                        figsize=(12, 7))

    sns.boxplot(x=data, ax=ax_box, color=color, fliersize=4)
    ax_box.set(xlabel='')
    ax_box.set_title(title, fontsize=16, fontweight='bold', pad=20)

    sns.histplot(x=data, ax=ax_hist, kde=True, color=color, bins=50)
    ax_hist.set_xlabel(f'Giá ({unit})', fontsize=12)
    ax_hist.set_ylabel('Số lượng bài đăng', fontsize=12)
    sns.despine(ax=ax_hist)
    sns.despine(ax=ax_box, left=True)
    plt.tight_layout()
    plt.show()

rent_prices = df_rent[df_rent['price'] < 50]['price'].dropna()
plot_dist_with_boxplot(rent_prices, 'PHÂN PHỐI GIÁ THUÊ (Đuối 50 triệu)', '#3498db', 'Triệu VND/tháng')

sale_prices = df_sale[df_sale['price'] < 20000]['price'].dropna()
plot_dist_with_boxplot(sale_prices, 'PHÂN PHỐI GIÁ BÁN (Đuối 20 tỷ)', '#e74c3c', 'Triệu VND')
```

Lấy top 10 dự án có nhiều tin đăng nhất

```
top_projects = df_sale['project_info.name'].value_counts().head(11)
if 'None' in top_projects or None in top_projects:
    top_projects = top_projects.drop(labels=[None], errors='ignore')
top_projects = top_projects.head(10)

project_prices =
df_sale[df_sale['project_info.name'].isin(top_projects.index)].groupby('project_info.name')['price_per_spm'].mean().sort_values(ascending=False)

fig, ax1 = plt.subplots(figsize=(14, 7))
sns.barplot(x=top_projects.index, y=top_projects.values, ax=ax1, alpha=0.6, color='blue', label='Số lượng tin')
ax1.set_ylabel('Số lượng tin đăng', fontsize=12, fontweight='bold')
ax1.tick_params(axis='x', rotation=45)
ax2 = ax1.twinx()
sns.lineplot(x=project_prices.index, y=project_prices.values, ax=ax2, marker='o', color='red', linewidth=2, label='Giá trung bình/m2)')
ax2.set_ylabel('Giá TB (Triệu/m2)', fontsize=12, fontweight='bold', color='red')
plt.title('TOP 10 DỰ ÁN NÓI BẬT: SỐ LUỢNG TIN VS GIÁ TRUNG BÌNH', fontsize=16, fontweight='bold')
plt.show()
```

Lấy Top 10 đặc trưng ảnh hưởng đến 'price'

```
features_to_check = [
    'price', 'area', 'price_per_spm', 'spec.front_width',
    'spec.road_width', 'spec.num_floor', 'spec.bedroom',
    'spec.bathroom', 'contact_info.listings', 'project_info.listing_count', 'verified_num'
]

corr_matrix = df_sale[features_to_check].dropna(subset=['price']).corr()
price_corr = corr_matrix['price'].drop('price', errors='ignore')
top_10_features = price_corr.abs().sort_values(ascending=False).head(10)
top_10_data = price_corr[top_10_features.index] # Lấy giá trị gốc để biết âm hay dương

plt.figure(figsize=(12, 8))
colors = ['#2ecc71' if x > 0 else '#e74c3c' for x in top_10_data.values]
sns.barplot(x=top_10_data.values, y=top_10_data.index, palette=colors)
plt.axvline(x=0, color='black', linestyle='-', alpha=0.3)
plt.title('TOP 10 ĐẶC TRUNG TÁC ĐỘNG MẠNH NHẤT ĐẾN TỔNG GIÁ', fontsize=16,
fontweight='bold', pad=20)
plt.xlabel('Hệ số tương quan', fontsize=12)
plt.ylabel('Đặc trưng', fontsize=12)

for i, v in enumerate(top_10_data.values):
    plt.text(v, i, f'{v:.2f}', va='center', fontweight='bold', color='black')

plt.tight_layout()
plt.show()
```

Bản đồ nhiệt phân bố tin đăng bất động sản tại Việt Nam

```
import folium
from folium.plugins import HeatMap

def clean_geo_data(df_input):
    temp_df = df_input.copy()
    temp_df['latitude'] = pd.to_numeric(temp_df['latitude'],
    errors='coerce')
    temp_df['longitude'] = pd.to_numeric(temp_df['longitude'],
    errors='coerce')
    return temp_df.dropna(subset=['latitude', 'longitude'])

df_geo = clean_geo_data(df_sale)
google_maps_vi_url =
'https://mt1.google.com/vt/lyrs=m&hl=vi&x={x}&y={y}&z={z}'
center_lat = df_geo['latitude'].mean()
center_lon = df_geo['longitude'].mean()
m_final = folium.Map(
    location=[center_lat, center_lon], zoom_start=11,
    tiles=google_maps_vi_url,
    attr='Dữ liệu @ Google Maps Việt Nam'
)
heat_data = [[row['latitude'], row['longitude']] for index,
row in df_geo.iterrows()]

HeatMap(
    heat_data, radius=15, blur=10, min_opacity=0.5,
    name='Mật độ tin đăng'
).add_to(m_final)

folium.Marker(
    location=[16.565141, 112.641903],
    popup='Quần đảo Hoàng Sa (Việt Nam)',
    icon=folium.Icon(color='red', icon='flag')
).add_to(m_final)

folium.Marker(
    location=[10.725116, 115.842338],
    popup='Quần đảo Trường Sa (Việt Nam)',
    icon=folium.Icon(color='red', icon='flag')
).add_to(m_final)

folium.LayerControl().add_to(m_final)
m_final.save('heatmap_bat_dong_san.html')
```

PHỤ LỤC 2

-o- Commits on Dec 27, 2025

Merge pull request #9 from thanglemvp-max/main	Verified	7338cad		
ptphat810 authored 7 hours ago				
Thang add 15 query		c54bfe0		
Le Dinh Nhat Thang committed 7 hours ago				
Thang Add OSDS progress report		41394fc		
Le Dinh Nhat Thang committed 7 hours ago				
Merge pull request #8 from nickeydinh/main	Verified	4263clc		
ptphat810 authored 17 hours ago				
update requirements		979a83d		
nickeydinh committed 18 hours ago				
Merge branch 'main' of https://github.com/nickeydinh/vn-real-estate-scraper		4f27db4		
nickeydinh committed 18 hours ago				
visual chart		b11dcf6		
nickeydinh committed 18 hours ago				
update EDA		49d74ad		
nickeydinh committed 18 hours ago				
update EDA		819348d		
nickeydinh committed 19 hours ago				
cập nhật file requirements cho phần trực quan		7857197		
nickeydinh committed 19 hours ago				
update path for modules		f3a7439		
ptphat810 committed yesterday				

-o- Commits on Dec 26, 2025

Merge branch 'main' of https://github.com/nickeydinh/vn-real-estate-scraper		e1174f8		
nickeydinh committed yesterday				
create EDA		f303cdd		
nickeydinh committed yesterday				
update code		e73e82a		
ptphat810 committed 2 days ago				
remove sqlite and update push data mongoatlas		2081b3c		
ptphat810 committed 2 days ago				
migrate data crawl to cloud	Verified	ddea54e		
ptphat810 authored 2 days ago				
delete the scraping_status.db archive file and replace it with mongodb atlas	Verified	2977106		
ptphat810 authored 2 days ago				
update 'verified' field boolean to string		d1b8e3f		
ptphat810 committed 2 days ago				

-o- Commits on Dec 25, 2025

Merge pull request #7 from nickeydinh/main	Verified	1fd403c		
ptphat810 authored 2 days ago				
Merge branch 'ptphat810:main' into main	Verified	100e7e0		
nickeydinh authored 2 days ago				
updata file cleaner		8de9be4		
nickeydinh committed 2 days ago				
Merge pull request #6 from nickeydinh/main	Verified	527259a		
ptphat810 authored 2 days ago				
add data for rent bds		4a71e3f		
nickeydinh committed 2 days ago				
update data to drive		ea7c4ad		
ptphat810 committed 3 days ago				

-o	Commits on Dec 24, 2025																												
	<table border="1"> <tbody> <tr> <td>update README.md</td> <td>47ac33e</td> </tr> <tr> <td>ptphat810 committed 4 days ago</td> <td>View Copy Compare</td> </tr> <tr> <td>create connect mongodb</td> <td>b3075e4</td> </tr> <tr> <td>ptphat810 committed 4 days ago</td> <td>View Copy Compare</td> </tr> <tr> <td>add new records</td> <td>2e84085</td> </tr> <tr> <td>ptphat810 committed 4 days ago</td> <td>View Copy Compare</td> </tr> <tr> <td>update code</td> <td>81ae500</td> </tr> <tr> <td>ptphat810 committed 4 days ago</td> <td>View Copy Compare</td> </tr> </tbody> </table>	update README.md	47ac33e	ptphat810 committed 4 days ago	View Copy Compare	create connect mongodb	b3075e4	ptphat810 committed 4 days ago	View Copy Compare	add new records	2e84085	ptphat810 committed 4 days ago	View Copy Compare	update code	81ae500	ptphat810 committed 4 days ago	View Copy Compare												
update README.md	47ac33e																												
ptphat810 committed 4 days ago	View Copy Compare																												
create connect mongodb	b3075e4																												
ptphat810 committed 4 days ago	View Copy Compare																												
add new records	2e84085																												
ptphat810 committed 4 days ago	View Copy Compare																												
update code	81ae500																												
ptphat810 committed 4 days ago	View Copy Compare																												
-o	Commits on Dec 22, 2025																												
	<table border="1"> <tbody> <tr> <td>fix error result return NoneType</td> <td>4b75eea</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add project info field and final pattern for schema json</td> <td>8fa4f6d</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>reupload data</td> <td>ad1af60</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>Delete data/raw directory</td> <td>4a4d026</td> </tr> <tr> <td>ptphat810 authored last week</td> <td>View Copy Compare</td> </tr> <tr> <td>delete wron format</td> <td>c1da982</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>update new records</td> <td>6803a35</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> </tbody> </table>	fix error result return NoneType	4b75eea	ptphat810 committed last week	View Copy Compare	add project info field and final pattern for schema json	8fa4f6d	ptphat810 committed last week	View Copy Compare	reupload data	ad1af60	ptphat810 committed last week	View Copy Compare	Delete data/raw directory	4a4d026	ptphat810 authored last week	View Copy Compare	delete wron format	c1da982	ptphat810 committed last week	View Copy Compare	update new records	6803a35	ptphat810 committed last week	View Copy Compare				
fix error result return NoneType	4b75eea																												
ptphat810 committed last week	View Copy Compare																												
add project info field and final pattern for schema json	8fa4f6d																												
ptphat810 committed last week	View Copy Compare																												
reupload data	ad1af60																												
ptphat810 committed last week	View Copy Compare																												
Delete data/raw directory	4a4d026																												
ptphat810 authored last week	View Copy Compare																												
delete wron format	c1da982																												
ptphat810 committed last week	View Copy Compare																												
update new records	6803a35																												
ptphat810 committed last week	View Copy Compare																												
-o	Commits on Dec 21, 2025																												
	<table border="1"> <tbody> <tr> <td>Rename eda.ipynb to processing.ipynb</td> <td>ba57346</td> </tr> <tr> <td>ptphat810 authored last week</td> <td>View Copy Compare</td> </tr> </tbody> </table>	Rename eda.ipynb to processing.ipynb	ba57346	ptphat810 authored last week	View Copy Compare																								
Rename eda.ipynb to processing.ipynb	ba57346																												
ptphat810 authored last week	View Copy Compare																												
-o	Commits on Dec 21, 2025																												
	<table border="1"> <tbody> <tr> <td>update and add new records</td> <td>0548823</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add get project info tab and update contact agent info</td> <td>ae314d4</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>update list</td> <td>aa9c00c</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add configuration file</td> <td>7b5282e</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>Merge pull request #4 from thanglelmvp-max/main</td> <td>9fa9466</td> </tr> <tr> <td>ptphat810 authored last week</td> <td>View Copy Compare</td> </tr> <tr> <td>refactor code and add spec for rent property</td> <td>a2237e6</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> </tbody> </table>	update and add new records	0548823	ptphat810 committed last week	View Copy Compare	add get project info tab and update contact agent info	ae314d4	ptphat810 committed last week	View Copy Compare	update list	aa9c00c	ptphat810 committed last week	View Copy Compare	add configuration file	7b5282e	ptphat810 committed last week	View Copy Compare	Merge pull request #4 from thanglelmvp-max/main	9fa9466	ptphat810 authored last week	View Copy Compare	refactor code and add spec for rent property	a2237e6	ptphat810 committed last week	View Copy Compare				
update and add new records	0548823																												
ptphat810 committed last week	View Copy Compare																												
add get project info tab and update contact agent info	ae314d4																												
ptphat810 committed last week	View Copy Compare																												
update list	aa9c00c																												
ptphat810 committed last week	View Copy Compare																												
add configuration file	7b5282e																												
ptphat810 committed last week	View Copy Compare																												
Merge pull request #4 from thanglelmvp-max/main	9fa9466																												
ptphat810 authored last week	View Copy Compare																												
refactor code and add spec for rent property	a2237e6																												
ptphat810 committed last week	View Copy Compare																												
-o	Commits on Dec 20, 2025																												
	<table border="1"> <tbody> <tr> <td>Thang Fixed data_cleaner file</td> <td>b42bd36</td> </tr> <tr> <td>Le Dinh Nhat Thang committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>update scripts run code</td> <td>80d2224</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>update insert data to mongodb and add notebooks for eda</td> <td>d8833aa</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>Delete src/test.py</td> <td>c91d170</td> </tr> <tr> <td>ptphat810 authored last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add logging module</td> <td>3e5c654</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add crawler engine, downloader and storage modules</td> <td>44f04e0</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> <tr> <td>add new records</td> <td>b9c235a</td> </tr> <tr> <td>ptphat810 committed last week</td> <td>View Copy Compare</td> </tr> </tbody> </table>	Thang Fixed data_cleaner file	b42bd36	Le Dinh Nhat Thang committed last week	View Copy Compare	update scripts run code	80d2224	ptphat810 committed last week	View Copy Compare	update insert data to mongodb and add notebooks for eda	d8833aa	ptphat810 committed last week	View Copy Compare	Delete src/test.py	c91d170	ptphat810 authored last week	View Copy Compare	add logging module	3e5c654	ptphat810 committed last week	View Copy Compare	add crawler engine, downloader and storage modules	44f04e0	ptphat810 committed last week	View Copy Compare	add new records	b9c235a	ptphat810 committed last week	View Copy Compare
Thang Fixed data_cleaner file	b42bd36																												
Le Dinh Nhat Thang committed last week	View Copy Compare																												
update scripts run code	80d2224																												
ptphat810 committed last week	View Copy Compare																												
update insert data to mongodb and add notebooks for eda	d8833aa																												
ptphat810 committed last week	View Copy Compare																												
Delete src/test.py	c91d170																												
ptphat810 authored last week	View Copy Compare																												
add logging module	3e5c654																												
ptphat810 committed last week	View Copy Compare																												
add crawler engine, downloader and storage modules	44f04e0																												
ptphat810 committed last week	View Copy Compare																												
add new records	b9c235a																												
ptphat810 committed last week	View Copy Compare																												

-o	Commits on Dec 19, 2025
	<p>Merge pull request #3 from nickeydinh/main ...</p> <p> ptphat810 authored last week</p> <p>update content for README.md</p> <p> ptphat810 committed last week</p> <p>add mongo client for database connection</p> <p> ptphat810 committed last week</p> <p>add project dependencies</p> <p> ptphat810 committed last week</p> <p>Update the scraper file to get a wider variety of links.</p> <p> nickeydinh committed last week</p>
	Verified 4210470 Copy Compare
-o	Commits on Dec 18, 2025
	<p>add scraped data</p> <p> ptphat810 committed last week</p> <p>Merge pull request #2 from thanglelmvp-max/main ...</p> <p> ptphat810 authored last week</p> <p>Thang add data cleaning script</p> <p> Le Dinh Nhat Thang committed last week</p>
	Verified 647e369 Copy Compare
-o	Commits on Dec 17, 2025
	<p>run code in source</p> <p> ptphat810 committed 2 weeks ago</p> <p>add duplicate_filter.py to remove duplicate records</p> <p> ptphat810 committed 2 weeks ago</p> <p>run code scraper.py and clener.py</p> <p> ptphat810 committed 2 weeks ago</p> <p>update extract_agent_info function</p> <p> ptphat810 committed 2 weeks ago</p> <p>Merge pull request #1 from nickeydinh/main ...</p> <p> ptphat810 authored 2 weeks ago</p> <p>add function to extract agent contact information</p> <p> ptphat810 committed 2 weeks ago</p> <p>Add a function to get real estate URLs</p> <p> nickeydinh committed 2 weeks ago</p> <p>Updated Thanhvien 2</p> <p> nickeydinh committed 2 weeks ago</p> <p>add extract coordinate from js</p> <p> ptphat810 committed 2 weeks ago</p> <p>add property detail parser ...</p> <p> ptphat810 committed 2 weeks ago</p> <p>Add some data fields</p> <p> ptphat810 committed 2 weeks ago</p> <p>update .gitignore</p> <p> ptphat810 committed 2 weeks ago</p>
	Verified a1610fa Copy Compare
-o	Commits on Dec 16, 2025
	<p>Add initial parser</p> <p> ptphat810 committed 2 weeks ago</p> <p>Updated Thanhvien 1</p> <p> ptphat810 committed 2 weeks ago</p>
	af314df Copy Compare
-o	Commits on Dec 16, 2025
	<p>Added Thanhvien.txt</p> <p> ptphat810 committed 2 weeks ago</p> <p>Initial commit</p> <p> ptphat810 authored 2 weeks ago</p>
	Verified 7a80177 Copy Compare
	Verified 221c196 Copy Compare